踩坑清单 · 课题 5

> 这份文档只记「花了时间才搞明白」的事。每条都写清：**现象 → 根因 → 正确做法 → 证据在哪。** 按「会不会再踩」排序，最容易再踩的放最前。 建立时间：2026-10-30

一、我自己判断错了、后来更正的（最危险，因为结论会连带错）

这一类最值得看——**判断错了会导致整份材料跟着错。**

坑 1：看到 WDL 报 RBRACE 就以为「平台不支持 heredoc」

- **现象**：WDL 校验报错 Expected one of: ... Previous tokens: [Token('RBRACE', '}')] at line 35, column 27
- **我的错误判断**：平台 WDL 解析器不支持 command 块里的 heredoc（<<'PATCH'）
- **真实原因**：我用的是 command { ... } 花括号形式，而命令段里有 Python 字典字面量 {"a": 1}，**里面的 } 把 command 块提前闭合了**
- **正确做法**：WDL 命令段一律用 command <<< ... >>> 三尖括号形式。改用后校验立刻通过
- **教训**：报错 token 是 RBRACE 时，先数一数命令里有没有裸的 }，别急着怪平台
- **证据**：docs/reports/batch-mixing-and-crossphylum-feasibility-20261019.md §8.6

坑 2：把「上传失败」当成通道坏了，其实文件已经落盘

- **现象**：GenPilot 报 samap_v98_emb.txt 上传失败，第二次还明确说「请在数据管理的操作记录查看失败原因」
- **我的错误判断**：平台上传通道阻塞，这条路走不通，准备放弃
- **真实情况**：samap_v98_emb.txt 和 opca_batch_metrics.txt **已经都在 /Files/ResultData/Notebook/ 里**了，只是延迟入库。我信了 GenPilot 的报错，没自己去列表核对
- **正确做法**：上传后**自己查一次文件列表**再下结论，不要只信返回消息
- **教训**：别人（包括 AI 助手）说「失败」，要用独立证据复核
- **证据**：同上 §8.6 第 1 条

坑 3：samap_emb 流程失败，我以为是 cp 命令没生效

- **现象**：任务跑完 16 分钟，产物只有一个 200 字节的 run.log，内容 python3: can't open file './samap_script.py': [Errno 2] No such file or directory

- **我的错误判断**：cp ${script_txt} ./samap_script.py 没生效，可能是 set -u 没配 set -e 导致错误被吞
- **真实原因**：那个流程**只声明了 2 个输入**（script_txt + pylibs_tar），三份 h5ad 从来没被 stage 进工作目录。就算 cp 成功了，脚本也会在读 ./human_saturn_input_s.h5ad 时崩
- **正确做法**：用 2026-10-05 跑通过的 runsamap 流程（5 个输入：三份 h5ad + 脚本 + pylibs）
- **教训**：WDL 失败先检查**输入声明是否完整**，再看命令段
- **证据**：docs/reports/batch-mixing-and-crossphylum-feasibility-20261019.md §8.8

坑 4：把 plan 里残留的「待埋点原件」当成事实

- **现象**：我一直以为 /Files 上的 samap_v98_emb.txt 是没打补丁的原件，需要另外准备一个打了补丁的版本
- **真实情况**：把它下载回来一看（17,194 B / 422 行 / SHA 418ac586…），**里面本来就有** EMB_SAVED 和 samap_joint_embedding.npy 的保存代码
- **正确做法**：把平台上的文件下回来核对 SHA 和内容，不要根据本地目录里的计划文档推断
- **教训**：计划文档会过期；**平台上的文件才是事实**
- **证据**：同上 §8.8

坑 5：以为「平台镜像构建通道失败」

- **现象**：多个文档里都写着「平台镜像构建通道失败」，我一直当既定事实
- **真实情况**：去镜像管理页数了一下，5 次尝试里**有 1 次成功**——g5-canary-pinned（2026-09-21 20:43，基于 SATURN--22）。另有 system 的 centos-7、zhongliyuan 的 SATURN--22 也是成功的
- **正确做法**：通道可用；失败集中在 SAMap/kBET 那种复杂依赖上
- **教训**：**「失败过」不等于「不能用」**，要数清楚成功率
- **证据**：container/README.md §7.4

坑 6：以为「本机没有 Docker」

- **现象**：容器化一直标为「本机无 Docker，无法构建」
- **真实情况**：docker --version 是 **29.8.2**，装了。真正的问题是 **WSL 一个发行版都没装**（wsl -l -v 报「没有已安装的分发」），Docker Desktop 的 Linux daemon 起不来
- **正确做法**：wsl --install -d Ubuntu（需重启）
- **教训**：诊断要往下追一层。「没有 X」往往其实是「X 装在，但依赖没配好」

坑 7：误判 scVI 首次失败「跑了 4.5 小时」

- **现象**：任务 W202610170092924 我看到页面显示已过 4.5 小时，就写进了文档

- **真实情况**：billing 只有 **566 秒（9.4 分钟）**，CPU 时间 29 秒。原因是我长时间没刷新页面，读的是**缓存的旧状态**
- **正确做法**：查任务详情接口或刷新页面取最新状态
- **教训**：**页面上的时间可能是缓存**，涉及「耗时/费用」的结论必须取自接口数据

坑 8：以为「torch 不存在」，其实是 anndata 冲突

- **现象**：import scvi 失败，我先怀疑镜像里没装 torch
- **真实情况**：二分测试（任务 W202610180098593）证明 **torch 2.6.0+cu124 在**。真正原因是 pylibs_full 里的旧 anndata 经 PYTHONPATH 抢在镜像自带 0.10.8 前面加载，而镜像里的 mudata 需要新版 anndata 的 AlignedViewMixin
- **正确做法**：解压 pylibs 后执行 rm -rf ./pylibs_full/anndata ./pylibs_full/anndata-*.dist-info
- **教训**：import 失败别猜，做**二分测试**（先只 import torch，再只 import anndata，最后 import scvi）
- **证据**：docs/execution/20261019-handoff-full.md §7.1

二、会烧钱或烧时间的坑

坑 9：Shell 变量不加引号 → 拷贝了整个根文件系统（¥0.58）

- **现象**：任务 IO 冲到 95 GB，费用 ¥0.58
- **根因**：写的是 if [-n $REC]; then。当 $REC 为空时，这行退化成 [-n]，bash 判定为**真**，于是执行了 cp -r $REC/. ./result/ → 变成 cp -r /. ./result/，开始拷根目录
- **正确做法**：**所有变量引用一律加引号**

```
[ -n "$REC" ]          # 不是 [ -n $REC ]
cp -r "$OUT"/. ./result/   # 不是 cp -r $OUT/.
```

- **教训**：这是 bash 最经典的坑，且在这里真的花了钱
- **证据**：docs/execution/20261019-handoff-full.md §7.3

坑 10：../result 在容器里不可写

- **现象**：任务 1 秒内失败，Container exited with status 1
- **根因**：WDL 命令段写 cp -r xxx ../result
- **正确做法**：mkdir -p ./result，WDL 里声明 File result = "./result"
- **证据**：同上 §7.2

坑 11：输出目录名不匹配 → 产物收集不到

- **现象**：任务成功但产物目录是空的
- **根因**：脚本写的输出目录是 opca-scvi-*，而 WDL 的 glob 找的是 opca-full-*
- **正确做法**：用 find 收集，且**变量必须加引号**

```
find . -name 'samap_joint_embedding.npy' -exec cp {} ./result/ \;
```

- **教训**：不要依赖固定目录名；find 比 glob 稳
- **证据**：docs/execution/20261019-handoff-full.md（输出目录一节）

坑 12：重复提交，白花钱

- **现象**：同一个任务出现两个号（W202610180071475 / W202610180071516），因为「运行」按钮点了两次
- **正确做法**：提交后**先确认任务列表出现了新任务号**，再继续操作；重复的用 POST /api/task/dcsTask/cancelTasks 取消
- **教训**：UI 上点一次不等于提交一次，要看结果确认

坑 13：跨门 scVI 预估严重偏低（¥2.06 / 3h29m）

- **现象**：预估 0.2–0.5 元，实际 ¥2.06、跑了 3 小时 29 分
- **根因**：55,694 细胞 × 50 epoch，规模是门内的 12 倍，时间非线性
- **教训**：**scVI 的耗时随细胞数近似线性增长**，5 万细胞级别要有心理准备。这不是 bug，是规模问题
- **证据**：docs/execution/20261019-handoff-full.md §6.3

三、平台操作坑

坑 14：下载文件时加自定义头会 401

- **现象**：带 X-Access-Token 等头请求 downloadFile 返回 401 令牌无效
- **正确做法**：**只带 cookie**（credentials: "include"），其他什么都别加

```
fetch("/api/data/file/downloadFile?id=<fileId>&projectId=<pid>&zone=st",
      { credentials: "include" })
```

- **返回的是 gzip 原始字节**（魔数 1f 8b 08 00），二进制文件**不能用 stringContent 端点**（会 UTF-8 解码损坏）

- **证据**：docs/execution/20261019-handoff-full.md §7.5

坑 15：文件列表接口缺 X-Client-App 头会 400

- **现象**：POST /api/data/file/meta/query 返回 {"code":400,"msg":"请求参数缺失：X-Client-App"}
- **正确做法**：加 X-Client-App: dcs-cloud-front

```
fetch(`/api/data/file/meta/query?projectId=${pid}&parentId=${parent}&zone=st`, {
  method: 'POST', credentials: 'include',
  headers: { 'Content-Type': 'application/json', 'X-Client-App': 'dcs-cloud-front' },
  body: JSON.stringify({ projectId: pid, parentId: parent, zone: 'st', pageNo: 1, pageSize:
100 })
})
```

- **注意**：downloadFile **不能**带这个头（带了反而 401），两个接口要求相反

坑 16：/api/task/dcsTask/getUserTaskById 同样要 X-Client-App

- **现象**：不带头返回 {"code":400,"msg":"请求参数缺失：X-Client-App"}
- **正确做法**：同上加头。**但**/api/data/file/downloadFile 不要加

坑 17：平台上传间歇失败（60030）

- **现象**：POST /api/data/file/upload/local/other 返回 code 60030「1 个文件上传失败」
- **两个附加坑**：

1. **.whl / .bin 等后缀会被内容检测拦截**，改名 .txt 上传，容器内去后缀恢复
2. **报失败不等于没上去**（见坑 2）

- **绕行**：GenPilot 容器内 dcs data push <本地路径> </Files/目标目录>（不支持 .py 后缀，改 .txt）

坑 18：镜像管理入口「消失」

- **现象**：直接在 #/project-management 项目列表页，项目卡片菜单里**没有**「镜像管理」
- **正确做法**：**必须先进入项目内部**（点「数据管理」或任何子页面），左侧菜单才会出现完整列表，其中才有「镜像管理」
- **补充**：这个页面偶尔白屏（内容 iframe display:none、innerText 为空），刷新或从项目卡片重进可恢复

坑 19：文件选择器藏在嵌套 iframe 里

- **结构**：外层 iframe[name^="Workflow__"] 内还套着 iframe[name="projectWorkflowV2Iframe"]
- **正确做法**：同源可直接用 outerIframe.contentDocument.querySelector('iframe[name=...]').contentDocument 操作

- **注意**：勾选框列被 CSS 隐藏（fixed--hidden），点行没用，要**点 td .text-over 带 checkbox 的兄弟节点**或用坐标点

坑 20：WDL 编辑器 fill() 只追加不替换

- **现象**：编辑已有流程的脚本时，fill() 把新内容**加在原文后面**，导致脚本损坏
- **正确做法**：新建流程时编辑器为空，一次写入即可；改已有流程要**先全选删除**
- **证据**：docs/execution/20261019-handoff-full.md

坑 20b：下拉显示「无数据」≠ 后端没数据（2026-10-30 新增）

- **现象**：「个性分析 → 离线任务 → 计算资源」两个级联下拉点开都是「无数据」，确定 不可用，任务提交不了
- **第一反应（错的）**：项目没绑资源池 / 接口故障 / 容器没起
- **真实原因**：整页 reload 后抓 performance.getEntriesByType('resource')，该页在 /stereonote/api/ 下**只发了 3 个请求**（user/info、ipynb/getProjectInfoById、workspace/getlast），**没有任何资源目录查询。**下拉从来没去后端取过数据
- **正确诊断法**：先看**请求有没有发**，再看返回。判断依据：

```
performance.getEntriesByType('resource')
  .map(r => r.name).filter(n => /stereonote\/api/.test(n))
```

数一数里面有没有 resource / remain / quota 这类端点。没有 → 前端没发请求，别去查额度

- **为什么不绕**：/stereonote/api/* 需要 X-Access-Token 头，直接 fetch 一律 {"code":401}；而按项目纪律不读取、不复用凭据
- **绕法**：走 UI 之外的路 —— 需要人先在平台上把容器起起来，之后用 dcs task run 投递
- **教训**：「空列表」有三种成因（没请求 / 请求失败 / 返回空），**先分清是哪一种再动手**
- **证据**：results/phase-20261030/image-build-evidence/offline-task-submit-blocked.json

四、方法学与数字坑（会导致结论错）

坑 21：旧草表数字作废但仍在多处流传

- **现象**：网上/旧 PPT 里到处是 80.9 / 38.3 / 40.5 / 22.4 / 11.9 / 79.5 这组 oPCA 数字

- **真实情况**：**已作废。**两个原因：① 排除规则失效（coarse_level=='unmapped' 字符串过滤一个都没命中，74 个该排除的细胞留在分母）；② 评分器不是统一那版（v75c/v78b 容器输出，与冻结的 KNN/置换定义有实现差异）
- **冻结值 v98 口径**：86.18 / 73.69 / 19.61 / 27.55 / 18.13 / 57.61
- ⚠ **2026-10-30 追补**：上面前四个数字里的鱼方向**是 v98 口径，已被 FIXKEY 取代。**v98 的斑马鱼方向同源映射没取反（已修 bug），FIXKEY 权威值为 17.95 / 26.75 / 17.34 / 58.14。人↔鼠两向两口径相同（86.18 / 73.69）。
- **所以真正的「正确数字」是 FIXKEY**：86.18 / 73.69 / 17.95 / 26.75 / 17.34 / 58.14
- **后果差别**：用旧草表是「4/6 个方向超过多数类基线」，用 v98 冻结值是「**3/6**」；用 FIXKEY 依旧是 3/6（差值 ≤1.4 个百分点，不翻转）
- **教训**：看到 80.9 那组立刻判定为旧草表；但**看到 19.61 那组要再判一次是不是 v98**
- **证据**：docs/checkpoint-flash-20261002-evening.md §4

坑 22：macro-F1 两个口径，差 0.05 就够翻转结论

- **现象**：同一份预测能算出两个 macro-F1
- **根因**：truth-only（只按真实标签集平均，平台 scVI 脚本默认） vs union（真实 ∪ 预测一起平均，多预测的类记 F1=0）
- **实例**：人→斑马鱼 coarse，truth-only 0.4516 / union 0.4014，**差 0.05**
- **正确做法**：跨方法比较**一律用 union**，从 18 份逐细胞预测独立重算
- **教训**：单独看 truth-only 不算错，但**不能和别的方法并列**

坑 23：把 shuffle_p 当成「优于多数类」的显著性

- **现象**：shuffle_p = 0.04，容易读成「这个方法显著更好」
- **真实含义**：它只回答「是否优于**随机打乱**」，**不回答「是否优于多数类基线」**
- **实例**：9 个斑马鱼方向的格子 acc < 多数类但 p≈0，属预期，不能写成「优于多数类」
- **证据**：docs/checkpoint-flash-20261002-evening.md §5.1

坑 24：included 旗标不等于分母

- **现象**：SAMap 的 per_cell 里 included=1,398，而 n_q=1,505，两个数不一样
- **根因**：included 用的是「truth ∈ 参考标签集」的新定义，**不参与 acc 计算**
- **后果**：误用 included 会得 158/1398 = 0.113，而正确值是 0.1050
- **教训**：引用时以后者（n_q/acc）为准

坑 25：批次指标的低值 ≠ 方法失败

- **现象**：三个方法 iLISI 都只有 1.006–1.120（满值 3），容易读成「都失败了」
- **真实含义**：同一份 scVI 潜空间上人→鼠 macro-F1 有 0.6683。潜空间把「细胞类型」和「物种」编码在近似正交的方向上
- **教训**：**两组证据必须一起报，只引一个就是误导**
- **证据**：docs/reports/batch-mixing-and-crossphylum-feasibility-20261019.md §7.2

坑 26：手写数字而不跑脚本

- **现象**：report-03 里六方向均值我按印象写成 0.4988/0.4200/0.3922，实际是 0.4986/0.4611/0.3857（SAMap 0.0334）
- **教训**：**所有表格数字必须从 metrics.json 用脚本生成**，或逐格核对。永远不要凭记忆写

五、工程协作坑

坑 27：中文引号与 Python 字符串冲突（两次）

- **现象**：生成组员文档的渲染脚本连续两次因引号转义失败，第二次还误把代码里的 "宋体" 改坏
- **正确做法**：**内容存 JSON，渲染脚本只读 JSON**。这样中文引号不会进入 Python 字符串字面量
- **落地**：docs/reports/report02-walkthrough-content.json + scripts/build_report02_walkthrough.py

坑 28：python-docx 设了列宽但 Word 不认

- **现象**：cell.width = Cm(x) 设完，渲染出来列宽全乱、内容挤成窄条
- **根因**：只设 cell 宽度不够，Word 需要同时有 tblGrid 列定义和 tblLayout=fixed
- **正确做法**：三样都要设

```
layout = OxmlElement("w:tblLayout"); layout.set(qn("w:type"), "fixed")
tbl.tblPr.append(layout)
grid = tbl.tblGrid
for i, w in enumerate(widths):
    grid.gridCol_lst[i].set(qn("w:w"), str(int(w * 567)))   # 567 twip = 1cm
for row in table.rows:
    for i, w in enumerate(widths):
        row.cells[i].width = Cm(w)
```

坑 29：Markdown → Word 渲染的四个小坑

- 三个连字符的分隔线渲染成字面文字（渲染器要显式处理成水平线）

- 由三个反引号包起来的代码围栏没被处理（要渲染成灰底等宽块）
- **列表项后面紧跟代码围栏**时，段落解析器会把围栏整段吞掉（循环的终止条件要把"这一行以三个反引号开头"也算进去）
- 表格单元格里"粗体套代码"（例如把 command 花括号形式写成加粗的代码片段）没解析干净，add_rich 要支持 bold 内嵌 code

坑 30：bash -n 的 exit code 被 Python 线程污染

- **现象**：bash -n container/entrypoint.sh 在 Python subprocess.run(capture_output=True, text=True) 里返回 1，但单独跑返回 0
- **根因**：文件里有中文，text=True 用 UTF-8 解码 stderr 时抛 UnicodeDecodeError，那个异常在线程里崩掉，returncode 就不可信了
- **正确做法**：检查 shell 语法直接跑 bash -n，别包在 Python 里；或加 errors='replace'

坑 31：容器 entrypoint 与脚本的环境变量契约不匹配

- **现象**：配方「看起来完整」，但从没真跑过
- **真实问题**：entrypoint.sh 只导出 OPCA_ORTH_DIR，但脚本 ortholog_pca_dcs_v3_fixkey.py 的 ORTH_DIR 变量**定义后再未使用**；脚本真正读的是 OPCA_ORTH_MGI / OPCA_ORTH_HF / OPCA_ORTH_MF，默认指向 /Files/wheelhouse/
- **后果**：容器里没有 /Files，**前置检查能过，脚本一 open 就 FileNotFoundError**
- **正确做法**：entrypoint 补齐三个变量。改完后用脚本静态比对「脚本读的 7 个变量 == entrypoint 导出的 7 个」
- ✅ **现状（2026-10-30 复核）**：已修。container/entrypoint.sh 现在同时导出 OPCA_H5AD_DIR / OPCA_ORTH_DIR / OPCA_ORTH_MGI / OPCA_ORTH_HF / OPCA_ORTH_MF / OPCA_MAPPING / OPCA_OUT 共 7 个，且第 39 行留了注释提醒
- **教训**：**「配方完整」和「跑得起来」是两件事。**没跑过的配方一定有坑
- **证据**：container/README.md §7.2

坑 32：Claude CLI 不可用

- **现象**：两次调用都返回 unrecognized_model: deepseek-v4-pro[1m]，并因超过 32000 输出 token 报错
- **教训**：这条路当时不通，别反复试

六、如果只记五条

1. **WDL 命令段用 command <<< >>>，不要用 command { }**（坑 1）
2. **Shell 变量一律加引号**，否则会 cp -r /. 拷根目录（坑 9）
3. **别人说「失败」要用独立证据复核**——文件可能已经上去了（坑 2）
4. **手写数字必错，一律跑脚本从 metrics.json 生成**（坑 26）
5. **没真跑过的配方一定有坑**，容器/流程要端到端验一遍（坑 31）

附：按症状查坑

你遇到的现象	看哪个坑
WDL 报 RBRACE	坑 1
文件「上传失败」但找不到原因	坑 2、17
任务成功但产物目录空	坑 11
任务 1 秒失败 Container exited with status 1	坑 10
import scvi 报 AlignedViewMixin	坑 8
下载文件 401「令牌无效」	坑 14
接口 400「请求参数缺失 X-Client-App」	坑 15、16
镜像管理菜单找不到	坑 18
文件选择器点不动	坑 19
WDL 编辑器内容越改越长	坑 20
Word 表格列宽全乱	坑 28
看到 80.9 / 38.3 这类数字	坑 21
macro-F1 和别人对不上	坑 22
脚本在容器里找不到输入文件	坑 31
页面显示耗时/费用很离奇	坑 7（可能是缓存）
下拉框显示「无数据」	坑 20b（先用 performance 数请求，别急着查额度）