课题 5 项目说明文档（组员版）

跨物种单细胞整合方法评估：我们做了什么、为什么这么做、现在到哪一步

2026-10-23 | 阅读时间约 20 分钟

0 先看这一页

如果你只有三分钟，看这五句：

- 我们在三种动物的心脏单细胞数据上，比较了四种「把细胞类型从 A 物种迁移到 B 物种」的方法。
- 四种方法各有胜负：近缘人-鼠是 ortholog-PCA 和 scVI 打平；远缘人-鱼是 scVI 最好；远缘鼠-鱼是 SATURN 最好。
- 没有哪个方法在所有方向都赢，所以我们不做「总分冠军」，而是做「场景 → 推荐哪个方法」的选型指南。
- 我们还试了最难的跨门场景（七鳃鳗 vs 小鼠）：最强的两个方法都失败了，这是个有价值的负结果。
- 课程要求的 12 项里，9 项已完成、3 项部分完成（批次指标只做了一个方法、时间内存非受控、容器未实际构建）。

1 课程要我们做什么

课程题目是：跨物种单细胞整合——SATURN vs SAMap vs scVI 系的基准测试与场景化选型。

拆开看是两件交付物：

- 一份基准测试报告：几种方法在同一份数据上、用同一套指标，跑出来到底谁高谁低。
- 一份场景化选型指南：至少覆盖近缘、跨门、无 GPU 三种场景，告诉别人「我这种情况该用哪个」。

课程还点名了几个指标：macro-F1（不是 accuracy）、批次混合与生物保守性（kBET/iLISI/silhouette）、时间与内存、文档易用性、Agent 友好度、容器化。

2 数据是什么

我们用的是心脏单细胞数据，三个物种：

物种	细胞数	备注
人（human）	1,528	心脏
小鼠（mouse）	1,535	心脏
斑马鱼（zebrafish）	1,543	心脏
合计	4,606	—

每个细胞都有一个「细胞类型」标签（比如心肌细胞、内皮细胞、成纤维细胞），这就是我们要预测的答案。

另外，跨门场景用的是另一套数据：LBSPA 论文的 8 物种脑数据，我们取了七鳃鳗 41,678 个细胞 + 小鼠 14,016 个细胞。

> 注意：心脏数据是 HEART 论文的小子集（每物种约 1,500 细胞），不是原文的 16 物种 47.9 万细胞。所有结论的适用范围都受这个规模限制。

3 四个方法分别是什么（用大白话）

任务本质：我有物种 A 的细胞（知道类型），想给物种 B 的细胞打类型标签。四个方法的区别在于「怎么把两个物种放到同一个空间里」。

3.1 ortholog-PCA（我们自己搭的基线）

做法：先把两个物种里一一对应的同源基因找出来（比如人的某基因对应鼠的某基因），只用这些基因，把两个物种的细胞一起做 PCA 降维，然后在降维空间里找最近邻。

特点：不训练、不用 GPU、30 秒跑完。它的作用是回答「这么简单的方法是不是已经够了」。

3.2 SATURN

做法：不直接比基因表达，而是把基因先翻译成蛋白质，用蛋白质语言模型（ESM2）得到嵌入，再把一堆基因压成「宏基因」（macrogene），在宏基因空间里对齐。

特点：需要 GPU 训练；思路是「越远缘，蛋白层面的相似性比基因表达更可靠」。

3.3 SAMap

做法：构建两个物种之间的同源基因图，用图对齐的方式找细胞对应关系。

特点：依赖多、复现最不稳定；在我们这个数据规模下基本没有信号。

3.4 scVI

做法：用一个生成模型（变分自编码器）把三个物种的细胞一起训练到一个 10 维的潜空间里，训练时告诉模型「每个细胞来自哪个物种」，让它学出不受物种影响的表示。

特点：需要训练但 CPU 就能跑（我们实测 8.5 分钟）；是课程点名的方法，也是 LBSPA 论文用的方法。

4 几个必须懂的概念

4.1 transductive（直推式）

意思是：测试数据在训练时「见过」。我们的做法是把两个物种的细胞一起放进去降维/训练，然后再评估能不能把标签从一边迁到另一边。

这不是留出评估，也不是 inductive（归纳式）。所以我们的结论只能说「在同一批数据上的一致性」，不能说「这个方法对全新物种也有效」。这条限定在每份材料里都必须写。

4.2 macro-F1 与 accuracy 的区别

accuracy = 预测对的细胞数 ÷ 总数。问题：如果 90% 的细胞都是同一类，全猜这一类也有 90% 的准确率。

macro-F1 = 先对每个类别各算一个 F1，再对所有类别取平均。少数类预测错了，会被明显惩罚。

我们最初用 accuracy，后来按课程要求改成 macro-F1，结果有 4 个结论直接翻转——原本「低于多数类基线」的方向，换成 macro-F1 后变成「高于基线」。

4.3 标签层级：exact / coarse / fine

同一批细胞有三套标签：exact（最细，原始注释）、coarse（粗类，9 类）、fine（细类）。层级不同，难度完全不同，所以我们的结果是 6 方向 × 3 层 = 18 格。

4.4 同源映射

把人的基因名对应到鼠/鱼的基因名。我们用的是一一对应的直系同源（1:1 ortholog）。人-鼠有 15,869 对，人-鱼 9,311 对，鼠-鱼 8,160 对。

5 结果一：门内四方法对比

这里的「门内」指三个物种都在脊椎动物门内（人、鼠、斑马鱼）。指标是 coarse 层的 macro-F1。

方向	ortholog-PCA	SATURN	SAMap	scVI
人 → 鼠	0.6435	0.4147	0.1127	0.6683
鼠 → 人	0.6729	0.4010	0.0401	0.5895
人 → 斑马鱼	0.1682	0.2479	0.0477	0.4014
斑马鱼 → 人	0.1585	0.4021	n/a	0.4290
鼠 → 斑马鱼	0.2314	0.6500	n/a	0.4248
斑马鱼 → 鼠	0.4396	0.6510	n/a	0.4786

怎么读这张表：

- 近缘（人↔鼠）：ortholog-PCA 和 scVI 基本打平，oPCA 略优（均值 0.658 vs 0.629）。
- 远缘人↔鱼：scVI 明显最好（0.4014 / 0.4290），SATURN 次之，oPCA 最弱。
- 远缘鼠↔鱼：SATURN 大幅领先（0.6500 / 0.6510），scVI 次之。
- SAMap 三个方向 n=0（没有细胞通过映射），其余方向 0.04–0.11，低于多数类基线。

结论：没有全面赢家。scVI 四个方向最高，oPCA 在鼠→人最高，SATURN 在两个鼠↔鱼方向最高。

6 结果二：批次混合（scVI 到底混得怎么样）

我们只在 scVI 的潜空间上算了三个指标：

指标	值	怎么理解
silhouette（细胞类型）	0.181	细胞类型结构存在，但不算清晰
iLISI（物种，k=30）	1.125	理论范围 1–3；接近 1 说明每个细胞的邻居几乎都是同物种
kBET 接受率	0.0039	几乎全部邻域的物种组成都与全局显著不同

三项一致说明：scVI 并没有把三个物种混匀，物种之间仍然分得很开。

但这看起来和「迁移效果不错」矛盾——同一份潜空间上，人→鼠 macro-F1 有 0.6683。

我们的解释：潜空间把「细胞类型」和「物种」编码在近似正交的方向上。同类型细胞跨物种彼此靠近，但单个细胞最近的 30 个邻居仍以本物种为主（物种方向的偏移量大于同物种内的类型间距）。

所以：低 iLISI 不等于方法失败，但两组证据必须一起报，只引一个就是误导。

这三个指标只有 scVI 有。其余三个方法当时没有保存嵌入，补齐需要重跑。

7 结果三：跨门场景（七鳃鳗 ↔ 小鼠）

这是课程明确要求覆盖的场景，也是最难的一个。七鳃鳗是现存最原始的脊椎动物，与小鼠隔了一个「门」。

7.1 数据与取舍

项	值	说明
细胞	55,694	七鳃鳗 41,678 + 小鼠 14,016
基因	6,222	两物种共同检测到的基因（min_cells≥3）
类别	13 类	七鳃鳗只有 13 类，是鼠类标签的子集
层级	仅 coarse	数据只有一套注释，没有 exact/fine

两个必须说明的取舍：

- 小鼠有 6 类细胞是七鳃鳗没有的（EX/IN/SNCG/Purkinje/Golgi/Bergmann），占小鼠细胞的 62.2%，全部排除出评估。
- 基因轴取两物种共同检测到的 6,222 个，七鳃鳗侧只有 56.7% 的基因是非零的。

7.2 结果（单元格是 accuracy / macro-F1）

方法	七鳃鳗 → 鼠	鼠 → 七鳃鳗	多数类基线
ortholog-PCA	0.0575 / 0.0711	0.0516 / 0.0732	0.2168 / 0.3059
scVI	0.0582 / 0.0652	0.0457 / 0.0802	0.2168 / 0.3059

13 类空间随机猜约 7.7%，两个方法实测 4.6–5.8%，低于随机；离多数类基线差 4–6 倍。

7.3 这条结果的价值

门内人→鱼时，scVI 是 oPCA 的 2.4 倍（0.4014 vs 0.1682）。到了跨门，两者都塌到 0.07 量级，没有实质差别。

说明「越远越要靠潜空间方法」这个规律，在跨门这一步中断了。可能的解释是：门内三物种共享脊椎动物身体计划与器官，细胞类型同源；跨门脑区与细胞类型本身缺乏可靠对应，不是换个方法能补的。

所以跨门的答案不是「哪个方法更好」，而是「在当前数据与注释体系下，这一族方法都做不了」。

8 为什么不能排一个总分冠军

有人会问：把六个方向平均一下不就行了？我们算过：

方法	六方向均值	说明
scVI	0.4986	最高
SATURN	0.4611	第二
ortholog-PCA	0.3857	第三
SAMap	0.0334	三个方向 n=0 按 0 计入；只算有值三方向是 0.0668

但这个排名不成立，原因有四条：

- 分母不同：oPCA 100%、scVI 98–100%、SATURN 29–87%、SAMap 0–91%。分母小的分数方差更大。
- 特征空间不同：scVI 用 9,018 个共同基因；oPCA 每方向独立（15,869 / 9,311 / 8,160）。这不是信息多少，是方法学约束不同。
- 训练方式不同：oPCA 是每方向独立 PCA；其余三个是一次训练、多方向评估。
- 统计强度不足：单 seed、无置信区间、无多重比较校正。0.05 的差距不足以支撑结论。

所以我们的做法是：不排总分，按场景推荐。

9 场景化选型建议（课程要的核心交付物）

场景	首选	次选	不推荐	证据强度
近缘（人 ↔ 鼠）	ortholog-PCA	scVI（很接近）	SAMap	中等
远缘 • 人 ↔ 鱼	scVI	SATURN	SAMap	中等
远缘 • 鼠 ↔ 鱼	SATURN	scVI	SAMap	中等
跨门（七鳃鳗 ↔ 鼠）	不建议（两法均失败）	—	—	中等（双臂实测）
无 GPU	ortholog-PCA	scVI（8.5 min）	SATURN	中等偏强

三条限定语必须随表一起出现：

- 全部是 transductive / in-sample，不是留出评估。
- 四个方法的分母不同，macro-F1 不能当绝对排名。
- 「不推荐」不等于「方法差」：SAMap 在我们这个规模下没信号，不代表它在原文 47.9 万细胞规模下无效。

10 我们踩过的坑（对后来人有用）

坑	现象	怎么解决
anndata 版本冲突	import scvi 报 AlignedViewMixin 找不到	删掉 pylibs 里的旧 anndata，让镜像自带的 0.10.8 生效
输出目录写错	任务 1 秒内失败	容器里只能写 ./result，写 ../result 不可写
shell 变量没加引号	cp -r $REC/. 变成 cp -r /. 拷贝根目录	所有变量加引号
macro-F1 两种口径	同一份预测两个数，差 0.05	跨方法对比统一用并集口径
平台上传通道	上传文件返回 60030	走 GenPilot 容器的 dcs data push

11 现在还缺什么

课程要求	状态	说明
四方法对比	完成	6 方向 × 3 层
macro-F1	完成	统一并集口径
近缘 / 无 GPU 场景	完成	有实测
跨门场景	完成	负结果，双臂实测
基准报告	完成	course5-final-report-v2
选型指南	完成	v4，八场景
文档 / Agent 友好度	完成	六维评分

批次混合与生物保守性	部分	只有 scVI 有；其余三方法需重跑
时间与内存	部分	有实测值，但不是受控 benchmark
容器化	部分	配方完整，未实际构建

12 项里 9 项完成、3 项部分。剩余三项都不是「没做」，是「做了但有明确缺口」。

12 交付物在哪

文件	位置
基准报告 v2	deliverables/course5-final-report-v2-20261023.docx
选型指南 v4	deliverables/场景化选型指南-v4-20261023.md
第 2 次汇报 PPT	results/stage-reports-20261019/课题 5 第 02 次汇报_数字来源链_校模板.pptx
第 5 次汇报 PPT	results/stage-reports-20261022/课题 5 第 05 次汇报_跨门场景.pptx
各次汇报内容稿	docs/reports/report-0N-*.md
四方法结果数据	results/phase-20261017/unified-coarse-macro-f1/
scVI 结果	results/phase-20261019/scvi-cross-species/
跨门结果	results/phase-20261022/crossphylum/
容器配方	container/
全项目交接文档	docs/execution/20261019-handoff-full.md

13 如果你要接手，从哪开始

按优先级：

- 先读《场景化选型指南 v4》，八场景看完就知道我们得出什么结论。
- 再读《基准报告 v2》，看数字怎么来的、限定是什么。
- 要改数字，先看 docs/reports/ 下对应的结果报告，每个数字都有来源文件。
- 要重跑，看 docs/execution/20261019-handoff-full.md 的复现章节（命令级）。

三条纪律：不把 transductive 写成 inductive；不按总分排冠军；限定语随数字一起出现。

本文所有数字来自平台产物或本地独立重算，未凭记忆填写。