课题 5 · 跨物种单细胞整合

四种方法
一张选型表

我们用三个物种的心脏细胞，测了「把细胞类型从一个物种搬到另一个物种」的四种做法，然后诚实地说清楚哪种在什么情况下靠得住。

2026-11-10 · 对外汇报版

先想象一件事

你手上有一本
人的细胞图鉴。

然后有人递给你一盒小鼠的细胞，

但它没有标签。

你要不要——用它，去猜？

但「另一个物种」有三个难度档

最容易	**人 ↔ 小鼠**	同属哺乳动物，基因基本能一一对上
中间档	**人 ↔ 斑马鱼**	隔了几亿年，只有部分基因还对得上
最难	**七鳃鳗 ↔ 小鼠**	连「门」都不同了，几乎只能靠猜

我们的任务：这三档都测，然后说清楚——哪种方法在哪一档靠得住。

四种做法，四种性格

不用记名字，记它靠什么

ortholog-PCA

只拿两本书共有的词

做对照表

27 秒 · 不用 GPU

scVI

让大家住进同一个小区

再按邻居判断

CPU 8.5 分钟

SATURN

不查词了

改看「意思」像不像

要 GPU 训练

SAMap

画一张两族人的族谱

再对着找

依赖最多、最不稳

留了一个「土办法」当基线：任何复杂方法，都得先证明自己打得过它。

先交代家底（这三个数字请记住）

4,606

个细胞

人 1,528 · 鼠 1,535 · 鱼 1,543

3

个难度档

近缘 / 远缘 / 跨门，全部实测

¥2.47

平台算力总花费

4 个任务，合计 3 小时 18 分

4,606 这个数字要背下来——因为它很小。

以后每讲一个结论，都要带一句「这是在这个规模上测的」。

第一个反直觉

「深度学习
必须用显卡」
在这套数据上不成立。

scVI 是深度生成模型，但 4,606 个细胞、 9,018 个基因这个规模，CPU 8.5 分钟就跑完了（平台实测含 IO 15 分 16 秒）。

→ 无 GPU 场景，我们因此有了第二个可选项。

谁赢了：一张表就够

coarse macro-F1（每类等权平均，不被大类绑架）· 数字越大越好

方向	最土基线	scVI	SATURN	SAMap
人 → 鼠	0.64	**0.67**	**0.35**	0.11
鼠 → 人	**0.67**	0.59	**0.26**	0.04
人 → 斑马鱼	0.17	**0.40**	0.13	0.05
斑马鱼 → 人	0.15	**0.43**	0.14	—
鼠 → 斑马鱼	0.22	**0.42**	**0.41**	—
斑马鱼 → 鼠	0.44	**0.48**	0.30	—

金子标出来的是每行最强。六行里五行是 scVI，只有「鼠→人」被最土的办法赢了。

「—」不是 0 分，是那个方向没有细胞能对上，没法评。

转折

但在讲结论之前，
我得先告诉你：
我们算错过一次。

而且是我们自己查出来的——查出来之后，所有数字都重算了一遍。

错在哪：查字典，查错了语种

规矩本来是这样的

真值 → 查【被预测方】的词表

预测 → 查【参考书方】的词表

我们写成了

真值 → 查【参考书方】的词表

预测 → 查【被预测方】的词表

后果：两边各丢一批细胞

① 真值查不到 → 直接跳过。
小鼠的「心肌细胞」在人词表里不存在（人分心房 / 心室），这些细胞就静默消失了。

② 预测查不到 → 记成「对不上」
再丢一次。人的「心房肌」在小鼠词表里也不存在。

打个比方：拿法语词典去查英语单词——不是查得慢，是查不到，然后你把它划掉了。

怎么证明「就是查错了」，而不是我事后找借口

拿同一份结果，按四种查表方式各算一遍。

只有「查错的那种」，能一字不差地复现我们原来的全部旧数字——六个方向全中，准确率也全中。

换句话说：不是我猜旧代码怎么写，是旧代码只能这么写，才可能算出那组数。

这一步叫「判定实验」。它是我们敢改结论的全部底气。

改完之后：排名没变，但理由变了

旧（错）

SATURN 0.65

比 scVI 的 0.42 高

新（对）

SATURN 0.41

比 scVI 的 0.42 低

而且六个方向一个都不赢

所以「鼠↔鱼用 SATURN」这个建议被推翻了。

但「远缘用 scVI」这个结论没变——它本来就不靠那一格撑着。

对外一律用「保留细胞、对不上算错」的口径，不用会丢样本的那种。

顺手还查出一个

「其他」被当成了「神经」。

斑马鱼的数据里有个类别叫 Orthers——那是 Others 的拼写错误，

意思是「实在归不了类」。

而我们的映射表，把它整个算成了「神经细胞」。

处理：这一类直接退出评估（它本来就不是一个细胞类型）。

另外两行「瓣膜算成纤维」「血管周细胞算平滑肌」保留，但写清依据和影响。

所以，三条结论

1 没有全面赢家

所以不排总分冠军，只做「什么场景用什么」的选型表

2 近缘，简单就够

人↔鼠基本打平；最土的办法 27 秒、不要显卡

3 跨门，这一族都做不了

七鳃鳗↔小鼠比随机猜还低——这是有价值的负结果

所有结论都限定在 4,606 个细胞、同批数据重评估。

最后，两件没做完的

我们不想把它讲成一个完成的故事。

容器的一步没跑

配方全部验证过，平台镜像也建好、镜像内 6 个值逐位复现；

但本机缺 WSL 发行版， docker build 那一条命令没执行。

生物学的签字只到「授权」

映射表 38 行已全部签认留痕，但那是项目负责人授权 + 程序复核；

不等于生物学同行逐行看过。要投稿，建议再找个人抽查 20% 。

如果只记一句：算得对是底线，分得对要人签字。