课题 5 汇报 · 逐页讲稿

配套文件：课题 5-汇报-讲故事版-20261110.pptx　|　用法：拿着纸念，不要看屏幕

三条提醒

- 方括号【】里的是动作提示，不要念出来。
- 每页只讲一个观点；讲完停一秒再翻页——停顿比语速重要。
- 被问到不会的，就说「这个我们没测，不能给结论」，比编一个强。

P01　四种方法

【开场，30 秒，看着人说，不要看屏幕】

"今天不讲一堆数字。就讲一件事：我们想知道，能不能拿一个物种的细胞图鉴，去推断另一个物种的细胞类型——以及，当我们以为找到答案的时候，是怎么发现自己错了的。"

停顿一下再翻页。

P02　你手上有一本

【讲这个场景，语速慢一点】

"人的细胞是标好类型的：这是心肌、这是内皮、这是免疫细胞。小鼠的没有标注。

那我们能不能拿人的这套'字典'，去给小鼠的细胞分类？"

再停一下，然后："这就是我们整个项目在解决的问题。"

注意：这里不要说任何数字，一句都不要。让听众先有这个画面。

P03 人 ↔ 小鼠

【这是全场最重要的框架，听众后面全靠它定位】

"难度不是一个词，是三个档。

人跟小鼠，很近，都是哺乳动物，基因基本能一一对上。

人跟斑马鱼，中间隔了几亿年，只有一部分基因还对得上。

七鳃鳗跟小鼠，连门都不一样了。"

然后指最后一行："我们三档都测了。这一步很关键——因为很多论文只测最容易那档。"

提醒自己：这页之后，每次提到一个场景，都先说它是哪一档。

P04 四种做法，四种性格

【这页要讲得轻快，用比喻，不要念参数】

"四种做法，性格完全不一样。

第一个 oPCA，最土：它只拿两个物种共有的词做对照表。27 秒，不用显卡。

第二个 scVI，是深度模型，但它干的事很朴素：让所有细胞住进同一个小区，然后按谁跟谁住得近来判断。

第三个 SATURN，不查词了，它把基因翻译成蛋白质语言，改看'意思'像不像。

第四个 SAMap，画族谱，按亲缘关系找。"

最后补一句（重要）："我们还特意留了最土的那个当基线。因为任何复杂方法，都得先证明自己打得过它。"

不要在这页报任何分数。

P05 4,606

【这页是"可信度"的铺垫，不是炫耀】

"先说清楚我们手里有多少东西：4,606 个细胞，三个物种，加起来。这个数字很小，我待会会反复提到它。

三个难度档都跑了。

有一点值得说：全部算力都在平台上跑完，一共四个任务，花了两块四毛七，三个小时出头。"

然后强调那句："4,606 很小。所以后面每一个结论，都只能限定在这个规模上说。"

如果有人问"是不是太少了"——老实说"是"，这正是我们每条结论都带限定语的原因。

P06 「深度学习

【这是个"小高潮"，讲的时候要有语气】

"有一件事我们本来以为做不到：scVI 是深度生成模型，一般都要显卡。

但在我们这个规模上——四千多个细胞——它 CPU 八分半就跑到完了。

这个发现直接改变了我们的选型建议：没有 GPU 的人，现在不只是能用最土的办法，还能用 scVI。"

如果被追问："因为数据小。换成几十万细胞就未必了。"——要主动补这句，显得你懂边界。

P07 谁赢了：一张表就够

【念两行，别念完六行】

"这张表就是我们的主结果。只看三件事：

第一，金色的是每行最强的。六行里有五行是 scVI。

第二，只有一行被最土的办法赢了——鼠→人。这一行说明什么？说明近缘场景里，简单方法真的够用。

第三，那些横杠不是零分，是'没法评'——那个方向没有细胞能对上。"

然后一句话收："所以我们的结论不是'哪个方法最好'，而是'什么场景用哪个'。"

千万不要逐格念数字。

P08 但在讲结论之前，

【这是全场最重要的三秒。停下来，看着大家】

"在讲结论之前，我得先承认一件事：我们中间算错过一次。"

（停三秒）

"不是小数点那种错。是会让排名反过来那种错。而且是我们自己查出来的。"

这页不要急着翻。让这句话落地，后面的可信度全靠这页。

P09 错在哪：查字典，查错了语种

【这页的核心是那个比喻，先讲比喻，再讲代码】

"每个物种的细胞类型是各自一套词。人分'心房肌、心室肌'，小鼠就统称'心肌细胞'。斑马鱼里甚至有个词叫 Orthers——那是 Others 的拼写错误，意思是'其他'。

规矩是：真值用被预测那方的词表，预测用参考书那方的词表。

我们把两边搞反了。

后果是两边各丢一批细胞：真值查不到的直接跳过——小鼠的'心肌细胞'在人词表里不存在；预测查不到的记成'对不上'再丢一次。

说白了就是：拿法语词典查英语单词。不是查得慢，是查不到，然后你把它划掉了。"

这页讲完，听众应该能自己推出"那分数一定会被抬高"。

P10 拿同一份结果，按四种查表方式各算一遍。

【这页要讲得硬，这是防"你凭什么说自己错"的挡箭牌】

"你可能会问：你说你错了，我怎么知道不是事后找借口？

做法是这样：拿同一份结果文件，按四种查表方式各算一遍。

结果只有'查错的那种'，能一字不差复现我们原来的全部旧数字——六个方向全中，准确率也全中。

换句话说：不是我猜旧代码怎么写，是旧代码只能这么写，才可能算出那组数。"

最后一句收："这一步是我们敢改结论的全部底气。"

如果被问"你怎么知道是旧代码错而不是新代码错"——答：因为生物学上真值只能是目标物种的注释，这个不是约定，是事实。

P11 SATURN 0.65

【先给旧数，再给新数，落差要说出来】

"改完是什么样？

原来 SATURN 在鼠↔鱼是 0.65，比 scVI 的 0.42 高一大截，所以我们当时写的是'鼠↔鱼用 SATURN'。

改完是 0.41，比 scVI 还低，而且六个方向一个都不赢。

所以那条建议被推翻了。"

然后一定要补这句（防止显得结论全崩）："但'远缘用 scVI'这个结论没变——它本来就不是靠那一格撑着的。"

最后那句口径的话，是给懂行的老师听的，讲快一点带过就行。

P12 「其他」被当成了「神经」。

【语气从"严肃"切回"轻快一点"，这是第二个错，不必太重】

"还有一个小的。

斑马鱼数据里有个类别叫 Orthers，是 Others 的拼写错误，意思是'实在归不了类'。

而我们的映射表把它整个算成了'神经细胞'。

我们的处理是：这一类直接退出评估——它本来就不是一个细胞类型。

另外两行，瓣膜算成纤维、血管周细胞算平滑肌，这两个是可以辩护的，所以保留，但把依据和影响写清楚。"

有个细节可以提（显得严谨）："顺便纠正一个流传的说法：旧文档里写'865 个细胞错归'是不准的，865 是被预测成这个类别的细胞数，真值侧只有 30 个。"

P13 没有全面赢家

【收束页，一条一条说，每条停一下】

"三条结论。

第一，没有全面赢家。所以我们的交付物不是'第一名'，是一张选型表。

第二，近缘场景，简单方法就够了。人跟小鼠基本打平，而最土那个办法 27 秒、不要显卡。

第三，跨门，这一族方法都做不了。准确率比随机猜还低。我们把它当有价值的负结果写下来，而不是藏起来。"

最后指底下那行："所有结论都限定在四千六百个细胞、同批数据重评估。"

如果时间不够，这页可以只讲第一条和第三条。

P14 最后，两件没做完的

【这页是加分项，也是最容易讲砸的一页——语气要平，不要像道歉】

"最后说两件没做完的。我们不想把它讲成一个完成的故事。

第一，容器的最后一步没跑成。配方全部验证过，平台镜像也建好了，镜像里六个值逐位复现。但本机没有 WSL，那条 docker build 命令没执行。我们知道差哪一步。

第二，映射表的签字只到'授权'这一层。38 行都签了、都有留痕，但那是项目负责人授权加程序复核，不等于生物学同行逐行看过。要投稿的话，建议再找个人抽查 20%。"

收尾那句："如果只记一句：算得对是底线，分得对要人签字。"
