课题 5 汇报 · 逐页讲稿

配套文件：课题 5-汇报-讲故事版-20261110.pptx　|　用法：拿着纸念，不要看屏幕

三条提醒

- 方括号【】里的是动作提示，不要念出来。
- 每页只讲一个观点；讲完停一秒再翻页——停顿比语速重要。
- 被问到不会的，就说「这个我们没测，不能给结论」，比编一个强。

P01　四种方法，一张选型表

【开场 30 秒，看着人说，不要看屏幕】

"今天不讲一堆数字。就讲一件事：我们想知道，能不能拿一个物种的细胞图鉴，去推断另一个物种的细胞类型——以及，当我们以为找到答案的时候，是怎么发现自己错了的。"

停一秒再翻页。

P02　人的细胞图鉴

【讲这个场景，语速慢】

"你手上有一本'人的细胞图鉴'——每个细胞都标好了类型：心肌、内皮、免疫。

然后有人递给你一盒小鼠的细胞，但它没有标签。

你要不要用它，去猜？"

停一下，再翻页。

P03 但「另一个物种」有三个难度档

【这是全场框架，听众后面全靠它定位】

"人跟小鼠很近，都是哺乳动物，基因基本能一一对上。

人跟斑马鱼，中间隔了几亿年，只有一部分基因还对得上。

七鳃鳗跟小鼠，连门都不一样了。"

最后一句："很多论文只测最容易那档。我们三档都测。"

P04 四种做法，四种性格

【讲得轻快，用比喻，不要念参数】

"oPCA 最土：只拿两个物种共有的词做对照表，27 秒、不要显卡。

scVI 是深度模型，但干的事很朴素：让细胞住进同一个小区，按邻居判断。

SATURN 不查词了，把基因翻译成蛋白质语言，看意思像不像。

SAMap 画族谱，按亲缘关系找。"

最后补："我们特意留了最土那个当基线。" 不报任何分数。

P05 4,606

【这是可信度铺垫，不是炫耀】

"4,606 个细胞，三个物种。这个数字很小，我后面会反复提到。

三个难度档都跑了。

全部算力在平台上，四个任务，两块四毛七，三个小时出头。"

然后强调："4,606 很小。所以后面每个结论，都只能限定在这个规模上说。"

如果问"是不是太少了"——老实说"是"。

P06 「深度学习必须用显卡」

【小高潮，要有语气】

"scVI 是深度生成模型，一般都要显卡。

但在我们这个规模上——四千多个细胞——它 CPU 八分半就跑完了。

所以没有 GPU 的人，现在不只是能用最土的办法，还能用 scVI。"

如果被追问："因为数据小。换成几十万细胞就未必。"——主动补这句。

P07 谁赢了：一张表就够

【只念两行，别念完六行】

"只看三件事：

第一，金色的是每行最强。六行里五行是 scVI。

第二，只有一行被最土的办法赢了——鼠→人。说明近缘场景，简单方法真的够用。

第三，「—」不是 0 分，是那个方向没有细胞能对上，没法评。"

收："所以结论不是'哪个方法最好'，而是'什么场景用哪个'。"

P08 我们算错过一次。

【全场最重要的三秒。停下来，看着大家】

"在讲结论之前，我得先承认一件事：我们中间算错过一次。"

（停三秒）

"不是小数点那种错。是会让排名反过来那种错。而且是我们自己查出来的。"

这页不要急着翻。后面的可信度全靠这页。

P09 错在哪：查字典，查错了语种

【先讲比喻，再讲代码】

"人分心房肌、心室肌；小鼠统称心肌细胞；斑马鱼里甚至有个 Orthers，是 Others 的拼写错误。

规矩：真值用被预测那方的词表，预测用参考书那方的词表。我们把两边搞反了。

后果是两边各丢一批细胞：真值查不到的跳过，预测查不到的记成'对不上'再丢一次。

说白了就是拿法语词典查英语单词。"

讲完，听众应该能自己推出'分数会被抬高'。

P10 怎么证明「就是查错了」

【这页要讲得硬，这是挡箭牌】

"做法是：拿同一份结果，按四种查表方式各算一遍。

只有'查错的那种'，能一字不差复现我们原来的全部旧数字——六个方向全中，准确率也全中。

换句话说：不是我猜旧代码怎么写，是旧代码只能这么写，才可能算出那组数。"

如果问"怎么知道是旧的错"——答：生物学上真值只能是目标物种的注释，这不是约定，是事实。

P11 SATURN 0.65

【先给旧数，再给新数，落差要说出来】

"原来 SATURN 在鼠↔鱼是 0.65，比 scVI 的 0.42 高一大截，所以我们当时写'鼠↔鱼用 SATURN'。

改完是 0.41，比 scVI 还低，六个方向一个都不赢。所以那条建议被推翻。

但'远缘用 scVI'没变——它本来就不靠那一格撑着。"

P12 「其他」被当成了「神经」。

【语气放轻，这是第二个错】

"斑马鱼数据里有个类别叫 Orthers，是 Others 的拼写错误，意思是'实在归不了类'。

而我们的映射表把它整个算成了'神经细胞'。

处理：这一类直接退出评估——它本来就不是一个细胞类型。

另外两行，瓣膜算成纤维、血管周细胞算平滑肌，可以辩护，保留，但写清依据和影响。"

可补："旧文档写'865 个细胞错归'不准，865 是被预测成这个类别的细胞数，真值侧只有 30 个。"

P13 所以，三条结论

【一条一条说，每条停一下】

"第一，没有全面赢家。所以交付物不是'第一名'，是一张选型表。

第二，近缘场景，简单方法就够了。人跟小鼠基本打平，最土那个 27 秒、不要显卡。

第三，跨门，这一族方法都做不了。准确率比随机猜还低。我们把它当负结果写下来，不藏。"

时间紧就只讲第一和第三条。

P14 最后，两件没做完的

【语气要平，不要像道歉】

"第一，容器的最后一步没跑成。配方验证过，平台镜像建好、镜像内六个值逐位复现；但本机没有 WSL，那条 docker build 没执行。我们知道差哪一步。

第二，映射表的签字只到'授权'层。38 行都签了、有留痕，但那不等于生物学同行逐行看过。要投稿建议再找个人抽查 20%。"

收尾那句，慢一点说。
