课题 5 · XenoTransfer v1.0

组员入门手册

跨物种单细胞整合：把这套流程讲到小白能复述

—— 给没做过单细胞分析的组员 ——

课题 5　第三次汇报配套材料

2026-11-04

目　录

第 1 章 我们到底在解决什么问题 4

1.1 先讲个厨房里的故事 4

1.2 "细胞类型注释"是什么，为什么非有不可 5

1.3 跨物种比同物种，到底难在哪 5

1.4 三个物种的家底 6

1.5 这章记住三句话 7

第 2 章 三个方法各是什么 7

2.1 先用不含术语的话说一遍 7

2.2 加上术语，精确说一遍 8

2.3 三方法强弱总表 8

2.4 三者不是"谁替代谁"，是"在什么场景下选谁" 9

2.5 这章记住三句话 10

附：本片数字来源 10

第 3 章：最重要的发现 —— 一个查表方向错误，让 SATURN 的分数虚高了 0.06–0.29.

3.1 先把现象说清：同一个方法，两套数字 .....

3.2 机关在哪：真值和预测，属于两个物种的词表 .....

错误写法（v1） .....

3.3 查反了会怎样：两类样本被静默丢掉 .....

3.4 判定实验：四种约定，只有错的那种能复现旧值 .....

3.5 修正后的数字，和「为什么仍算结论翻转」 .....

第 4 章：三场景结论 14

4.1 近缘：人 ↔ 鼠 14

4.2 远缘：鱼参与的四个方向 15

4.3 跨门：七鳃鳗 ↔ 小鼠 —— 为什么这是最差的一档 16

4.4 我们同时报两个口径，对外用公平口径 17

本篇标了「待确认」的地方 17

第 5 章　为什么我们这么强调"可复现" 18

5.1 sha256 冻结：给每个文件发一张"身份证" 18

5.2 环境记录：证明"在哪跑出来的" 19

5.3 产物目录结构：每个文件各管一件事 19

5.4 为什么"能复现"比"分数高"更重要 20

第 6 章　组员最容易问的 10 个问题（FAQ） 20

Q1　SATURN 是不是没用？ 20

Q2　为什么我们的数字和别人论文里不一样？ 20

Q3 oPCA 这么快，为什么不全都用它？.....21
Q4 86.18% 这个数是怎么来的？为什么说它"依赖未签认的映射表"？.....21
Q5 什么叫"算得对"不等于"分得对"？.....21
Q6 跨门为什么效果这么差？是不是方法不行？.....21
Q7 平台标"失败"的任务是真的失败吗？.....21
Q8 为什么要同时报两个口径？只报公平口径不行吗？.....22
Q9 老师七条意见我们到底怎么落的？.....22
Q10 我想自己跑一遍，从哪开始？.....22

> 面向：大一 / 大二，没做过单细胞分析。
>
> 本片覆盖 **第 1 章（我们在解决什么问题）** 与 **第 2 章（三个方法各是什么）**。
>
> 所有数字来自 `deliverables/课题 5-总交接文档-20261028.docx` 与 `deliverables/场景化选型指南-v6-20261027.md`，未自行编造。

第 1 章 我们到底在解决什么问题

> **这章讲什么**：这个项目到底在干什么，为什么"跨物种比较"不是一件显然的事。
>
> **为什么重要**：后面所有方法、所有分数，都只在这个问题框架里才有意义。跳过这章，第 2 章那三个缩写对你就是天书。

1.1 先讲个厨房里的故事

假设有三个厨师，各写了一份菜谱：

- 中国厨师（对应 **人**）
- 日本厨师（对应 **小鼠**）
- 一个来自很远地方的厨师（对应 **斑马鱼**）

三份菜谱用的是三种语言，连"盐"这个字都长得不一样。

你想知道的**不是**"谁的菜谱写得漂亮"，而是：**他们做的到底是不是同一道菜？**

但你不能直接把菜谱摊开对，因为有三个坑：

1. **文字不通**——"盐" / "塩" / "salt" 得先对上号；
2. **有的菜名根本没有对应**——中国菜谱里的"高汤"，日本菜谱里没有单独这一条；
3. **份量标准不同**——一份写"少许"，另一份写"3.5 克"。

所以正确做法是：**先把三份菜谱翻译成同一份标准菜谱**（统一语言、统一单位、统一分类），**再比谁做出来的东西更像**。

这就是"跨物种单细胞比较"：

厨房里的东西	项目里的东西
菜谱	基因表达（每个细胞里哪些基因开着、开多大）
翻译成标准菜谱	把不同物种的基因映射到同一套"同源基因轴"上
比谁做得好吃	A 物种已知类型的细胞，能不能正确给 B 物种的细胞打上类型标签

术语版一句话：跨物种单细胞整合（cross-species single-cell integration）= 把多个物种的单细胞转录组数据映射到共同的表示空间，使同一细胞类型在不同物种之间可比。

> 顺带解释两个词：
>
> **单细胞转录组**（single-cell RNA-seq）= 把一块组织拆成一个个单独的细胞，分别测出每个细胞里所有基因的活跃程度，结果是一张"细胞 × 基因"的大表格。

> **降维**（dimensionality reduction）= 这张表有几万列（基因），人眼看不了、算距离也算不准，先用数学方法把它压成几十列，同时尽量不丢信息。

1.2 "细胞类型注释"是什么，为什么非有不可

一次单细胞实验的产出，就是一张表：每行一个细胞，每列一个基因，格子里是"这个基因在这个细胞里被测到多少次"。

问题来了：**这张表里没有任何一列叫"细胞类型"。**

仪器只告诉你"这里有一个细胞，它有这些基因在活动"，它不告诉你这是心肌细胞、成纤维细胞还是免疫细胞。

细胞类型注释（cell type annotation，就是给每个细胞贴上一个类型标签）= 根据这个细胞表达了哪些基因、最像哪一类已知细胞，判定它属于哪一类。

为什么必须做：

- 没有标签，你只能做无监督聚类（把相似的细胞自动堆成堆），但堆出来的每一堆**叫什么你不知道**，也就无法判断对错；
- 有了标签，才谈得上"对不对"——才能算准确率、macro-F1 这些指标；
- 跨物种比较的核心任务，本质就是 **标签迁移**（label transfer）：A 物种的标签是已知的，拿它去猜 B 物种每个细胞的标签，再和 B 的真实标签比。

一句话：**注释既是任务的前提，也是评分的标准答案。**

> **macro-F1**（一种打分方式，中文叫"宏平均 F1"）= 先对每个细胞类型单独算一次"查得准 + 查得全"的综合分，再对所有类型**等权平均**。它和 accuracy（总体正确率）的区别是：accuracy 会被"数量最多的那一类"绑架，macro-F1 会让少数类也被惩罚到。本项目主指标用 macro-F1，原因见后文。

我们的数据带三层标签：

层级	含义	用途
exact	原始注释，最细的叫法	溯源、对照原文
fine	细类	精细评估
coarse	粗分，**9–10 类**	跨物种比较主要用这一层（越粗的类别，跨物种越可能真的对应）

1.3 跨物种比同物种，到底难在哪

同物种比较时，基因是同一套、细胞类型的名字是同一套、样本量差不多——三样都顺。

一到跨物种，三样全崩。下面三个难点，是本项目一切设计的根源。

难点一：同源基因对不上，一对一的只有一部分

同源基因（ortholog，不同物种里由同一个祖先基因传下来、功能大致对应的基因）是跨物种比较唯一的桥。

但这座桥很窄——我们在整个基因池里，只能挑出**一对一（1:1）直系同源**的那些：

物种对	1:1 同源对数
人 ↔ 小鼠	15,869
人 ↔ 斑马鱼	9,311
小鼠 ↔ 斑马鱼	8,160

对比一下基因总数（每物种 27,519–32,732 个），就能看出**大量基因在对面没有对应项**，映射时只能被丢掉。

丢得越多，信息损失越大；而斑马鱼与人的进化距离最远，丢得最狠——这直接解释了后面"人 ↔ 斑马鱼方向分数最低"。

难点二：细胞类型的名字不统一

同一类细胞，三份数据里可能写成三个名字。更麻烦的是**有些类型只存在于一个物种**。

真实例子（跨门脑数据）：小鼠有 6 类细胞（EX / IN / SNCG / Purkinje / Golgi / Bergmann）在七鳃鳗里完全没有，这些细胞占小鼠总量的 **62.2%**，只能整批排除出评估。

所以每个项目都必须先手工做一张**标签映射表**（把各物种自己的叫法统一到一套标准名）。

我们的是 `config/heart-celltype-map-v1.tsv`：38 行、35 个 active、3 个 unmapped。

这张表不是配菜——它决定哪些细胞有资格参加评估，换一种映射，分母就变，分数就会变。

难点三：规模差几百倍

数据集	细胞数	相对门内
本项目门内（三物种心脏）	4,606	1×
跨门（七鳃鳗 + 小鼠脑）	55,694	约 12×
HEART 原文（16 物种）	47.9 万	约 100× 以上

规模一变，**方法的可用性就变**：我们的 scVI 在 2 核 CPU 上 8.5 分钟跑完；到 10 万细胞级别就必须上 GPU。

所以我们的所有结论**只在这个规模上成立**，这句话必须随每一个数字一起出现。

1.4 三个物种的家底

物种	细胞数	基因数	与人的 1:1 同源对	与小鼠的 1:1 同源对
人 human	1,528	32,732	—（自身）	15,869
小鼠 mouse	1,535	32,379	15,869	—（自身）
斑马鱼 zebrafish	1,543	27,661	9,311	8,160
合计	**4,606**	—	—	—

补充口径：

- 数据文件：`local_human_s.h5ad` / `local_mouse_s.h5ad` / `local_zebrafish_s.h5ad`；
- 标签三层：`exact` / `fine` / `coarse`（coarse 为 9–10 类）；
- 跨门对照数据：LBSPA 8 物种脑数据子集的七鳃鳗 41,678 + 小鼠 14,016 细胞，共同基因轴 6,222；
- scVI 用的是三物种联合训练的**共同人类基因轴 9,018 基因**——和 oPCA 的"每方向独立成对基因集"不是同一条轴，这会影响跨方法比较。

> ⚠ **待确认（同源对数有两版）**：上表用数据表口径 15,869 / 9,311 / 8,160（人-鼠 / 人-鱼 / 鼠-鱼）。但 2026-10-31 容器复现日志打印的是 `hm=17,611 fh=10,398 fmm=9,058`。两版差异原因未核清（可能是映射版本或过滤阈值不同）。**引用时务必注明用的是哪一版。**
>
> ⚠ **待确认（coarse 类数）**：素材只写"粗分 9–10 类"，未逐物种列出确切类数。

1.5 这章记住三句话

1. 我们要做的事：把三个物种的细胞数据翻译到同一套标准坐标上。
2. 任务形式：用 A 物种已知的细胞类型标签，去猜 B 物种每个细胞是什么类型，**猜得准不准就是方法的好坏**。
3. 三个坑：同源基因只有一部分能对上、细胞类型名字不统一、数据规模差一到两个数量级。

第 2 章 三个方法各是什么

> **这章讲什么**：oPCA / scVI / SATURN 三个方法，分别是"怎么翻译菜谱"的三种做法。
>
> **为什么重要**：整份选型指南的全部依据，就是这三条路各自的强弱差异。搞清楚它们**各自怕什么**，你才知道什么时候该用谁。

2.1 先用不含术语的话说一遍

oPCA（同源基因主成分分析）

> 把两边能对上的基因挑出来，直接做一次压缩，然后比相似度。
>
> 相当于：**只翻译双方共有的词汇，然后逐句对照**。

scVI（单细胞变分推断）

> 把两个物种的细胞丢进同一个模型里一起训练，让模型自己学出一套低维坐标，同类型的细胞在坐标里自动靠近。
>
> 相当于：**请一个翻译，让他把全部菜谱读完，自己总结出一份标准版**。

SATURN

> 先把每个基因翻译成"蛋白质的语言"，再把一堆基因压成若干个"超级基因"，用超级基因来比。
>
> 相当于：**不逐句翻译，而是先提取每道菜的"风味特征"，再比风味像不像**。

为什么 SATURN 要走这条绕路？因为它想绕开 1.3 的第一个坑——基因名字对不上。**蛋白序列比基因名更保守**：两个物种的基因即使名字不同、序列有差异，它们编码的蛋白质功能往往还很像。所以"比蛋白"比"比基因名"更抗跨物种。

2.2 加上术语，精确说一遍

方法	一句话定位（术语版）
ortholog-PCA（oPCA）	取两物种的 1:1 直系同源基因交集，各自标准化后在共同基因轴上做 **PCA**（主成分分析，找方差最大的几个方向当新坐标），降到 50 维，再用 **KNN**（k 近邻，看最近的 k 个已知标签细胞投票）做标签迁移。
scVI	一个 **VAE**（变分自编码器，一类"压缩再还原"的神经网络），把基因计数建模为负二项分布，把两物种细胞放在一起训练，输出 **10 维** batch-corrected **潜空间**（latent space，模型自己学出来的低维坐标，不是原始基因）。
SATURN	用 **ESM2**（一个蛋白语言模型，输入氨基酸序列输出向量）为每个基因生成蛋白嵌入，再通过**宏基因**（macrogene，把上千个基因加权压缩成几百个"超级维度"）压缩表示，使不同物种的基因即便序列不同也能按蛋白功能对齐。本项目压缩到 **1,000 维**。

2.3 三方法强弱总表

这是本片最重要的一张表。**"强 / 弱"两列不是主观评价，每一项都有数字或实测撑腰。**

方法	一句话定位	强在哪	弱在哪	我们为什么选它
oPCA	不做训练、只做一次压缩的**快速基线**	无需训练、无需 GPU；实测 **约 27 秒**（本机 6 方向全量，26.7 秒 / 峰值 1.31 GB）；完全确定性（同输入必同输出）；文档与 Agent 友好度 **26/30**，可无人值守	依赖 1:1 同源对，对应关系弱时信息损失大；**远缘场景全面落后**——人→斑马鱼仅 **0.1654**；批次混合指标也是三者最弱之一	它是**下界基线**。任何复杂方法必须先证明自己赢得过它，否则就不值得用
scVI	联合训练出潜空间的**深度生成模型**	两物种细胞一起训练，远缘场景反超；**CPU 8.5 分钟**（2 核，4,606 细胞 × 9,018 基因 × 50 epoch，峰值 2.37 GB；平台 2c8g 含 IO 实测 15m16s）；潜空间可复用做聚类 / 可视化	需要训练、需要调 epoch；首次安装有依赖版本冲突，需要人介入一次；SATURN / SAMap / scVI 各只训练一次，**seed 波动未测**；批次混合三项相对最好但绝对水平仍低	它证明了"**深度学习必须 GPU**"这个假设在 1,500 细胞/物种规模上**不成立**——这是本项目最反直觉的结论
SATURN	靠蛋白语义对齐的	专用设计正面绕	需要 **GPU**（原训练	它是"**专用路线**"的

	跨物种专用方法	开"基因名对不上"；宏基因压缩后表示稳健；**但原报告的鼠↔鱼「大幅领先」是评测 bug 造成的**，修正后为 0.3658 / 0.3563，不再领先任何方向	在 3080Ti）；部署最麻烦（镜像、蛋白嵌入 .pt 全要自己准备）；文档/Agent 友好度仅 **14/30**；n_q 只有 1499–1528，分母小方差大；批次指标已核实为**"不可补"**（原训练命令丢失，重训会破坏可比性）	代表。选它进来就是要检验：为跨物种专门设计，到底比通用方法强多少

两个必须跟着看的口径警告

警告一：SATURN 在鼠↔鱼方向的"领先"在公平口径下翻转了。

2026-11-08 复核发现：旧算法的 macro-F1 偏高，根因是**评测把真值按源物种词表、预测按目标物种词表查表**（方向颠倒），造成两侧各丢一批细胞。四种约定重算，只有错的那种能复现全部旧值（6/6，accuracy 亦 6/6）。修正后 SATURN 六向为 **0.3522 / 0.2566 / 0.1269 / 0.1640 / 0.3658 / 0.3563**，**一个方向都不赢**；分母同时与其他方法拉齐到 1499–1528。详见 docs/reports/report-09-corrections-20261108.md。

所以本项目的结论已改为：**鱼的四方向全部 scVI 领先**。旧版（v6 选型指南）里"鼠↔鱼 SATURN 首选"、以及旧回应稿里「公平口径 0.4560 / 0.4588」的说法**均已作废**——看到旧文档请以 场景化选型指南-v7-20261108.md 与 docs/execution/20261108-更正索引.md 为准。

警告二：四个方法的分母不同，分数不能直接比大小。

方法	可评估细胞占比
oPCA	97–100%
scVI	97–100%
SATURN	**97–100%**（2026-11-08 更正后；旧文档写的 29–87% 是查表 bug 造成的）
SAMap	0–91%

分母小的方差更大。真正的比较必须落在**同一批细胞**上（配对检验），不能只看两个百分数谁高。

2.4 三者不是"谁替代谁"，是"在什么场景下选谁"

这句话请记死：这三个不是"谁替代谁"的关系，是"在什么场景下选谁"的关系。

不存在"SATURN 出来后 oPCA 就废了"这回事。原因很实在：

- oPCA 慢在能力、快在速度——27 秒跑完，别人还在装环境；
- scVI 强在远缘、弱在要调参——装一次环境就能用，但版本冲突第一次会咬你；

- SATURN 强在专用、弱在门槛——强到能赢，也可能因为缺一个 `.pt` 文件而完全跑不动。

按场景选：

你的处境	选谁	依据（数字）
只有 CPU，想先把流程跑通	**oPCA**	约 27 秒，无需训练
人 ↔ 小鼠（近缘）	**oPCA 或 scVI**，基本打平	两向均值 0.6582 vs 0.6289；配对检验一侧不显著、一侧 oPCA 显著更高
人 ↔ 斑马鱼（远缘）	**scVI**	0.4014 vs oPCA 0.1654（约 2.4 倍）
鼠 ↔ 斑马鱼（远缘）	**scVI**	SATURN 修正后 0.3658 / 0.3563，四向全面落后
跨门（七鳃鳗 ↔ 小鼠）	**都不行**	两法准确率 4.6–5.8%，随机猜约 7.7%，多数类基线 21.7% / 30.6%

最后一行是这份手册里最重要的诚实：跨门不是"数据不够"或"没调好"，而是当前这套「共同基因轴 + 单层细胞类型注释 + KNN 标签迁移」的范式在这个尺度上不成立。把这个负结果写清楚，比含糊地说"未做"有价值得多——**它排除了一条路**。

2.5 这章记住三句话

1. **oPCA 是快速基线**（27 秒、免训练），一切复杂方法都得先赢过它。
2. **scVI 是深度生成模型**（8.5 分钟 CPU 就够），远缘场景的主力。
3. **SATURN 是跨物种专用**（蛋白嵌入 + 宏基因），强但要 GPU、门槛最高。

记住第 4 句：选型不是排名，是匹配——**先问"我在什么场景"，再问"该用谁"**。

附：本片数字来源

内容	来源
三物种细胞数 / 基因数、四方法定位与开销、跨门数据	课题 5-总交接文档-20261028.docx §0 / §1 / §4 / §9.4b
macro-F1 各方向数值、口径修订（SATURN 公平口径、FIXKEY）	同上 §2、§5，及 §10 的三处修订说明
同源对数（数据表口径）、标签层级	同上 §1 数据表
同源对数（容器日志口径 17,611 / 10,398 / 9,058）	同上 §9.4b 容器复现日志
场景推荐、批次指标、transductive 限定	场景化选型指南-v6-20261027.md 场景 1–9、四条限定语

> 引用任何 macro-F1 时，必须同时带三件事：**union 口径 + 分母 n_q + transductive**。

> 本篇是入门手册最核心的一段。读完应能做到两件事：**看到任何跨方法比较的分数，先问分母是什么；拿到一个物种对，能说出该用哪个方法、为什么。**
>
> 数字来源：场景化选型指南-v7-20261108.md（下称「选型指南」）与 docs/reports/report-09-corrections-20261108.md（下称「更正报告」）。
>
> ⚠ 2026-11-08 更正：本章第 3 章整章重写过——旧章讲的「SATURN 输出无法映射的标签被丢弃导致虚高」这个机制已被推翻，真相是真值/预测的**物种词表查反了**。数字全部更新。

第 3 章：最重要的发现 —— 一个查表方向错误，让 SATURN 的分数虚高了 0.06–0.29

3.1 先把现象说清：同一个方法，两套数字

我们的主指标是 **macro-F1**（宏平均 F1：先给每个细胞类型各算一个 F1，再对所有类型等权平均。好处是「只有几十个细胞的稀有类型」和「几千个细胞的常见类型」权重一样，不会被大类型淹没）。

远缘场景（鼠 ↔ 斑马鱼）最初的表是这样的：

方向	SATURN	scVI	看上去的结论
鼠 → 斑马鱼	**0.6500**	0.4248	SATURN 大胜
斑马鱼 → 鼠	**0.6510**	0.4786	SATURN 大胜

2026-11-08 复核后发现：**这一列 SATURN 全部偏高**。修正后是：

方向	SATURN（修正后）	scVI	结论
鼠 → 斑马鱼	**0.3658**	0.4248	scVI 更好
斑马鱼 → 鼠	**0.3563**	0.4786	scVI 更好

注意：这次不是「又换了个口径」，而是**原来那套算法本身有 bug**。区别很重要——换个口径是选择，改了 bug 是纠错。

小结一句：分数高不等于方法好，先确认「这个分数是怎么算出来的」。

3.2 机关在哪：真值和预测，属于两个物种的词表

这是整章最需要慢读的一段。

第一步，认识「词表」这件事。 每个物种的细胞类型注释是**自己一套词**。人会说 Ventricular Cardiomyocyte（心室肌）和 Atrial Cardiomyocyte（心房肌）；小鼠说 Cardiomyocyte（不分房室）；斑马鱼的注释里甚至有个 Orthers——那是 Others 的拼写错误，本质是「无法归类」的收容桶。

第二步，知道评测时两侧的标签分别来自谁。 跨物种标签迁移是「拿 A 物种当参考书（有注释），去预测 B 物种（有真值）」：

	用谁的词表
真值（truth）	**目标物种**（B，被预测的那一方）
预测（pred）	**源物种**（A，参考书那一方；SATURN 输出的是 A 的原始类型名）

验证方法很简单：把人→鼠的混淆矩阵两边标签打出来看——真值侧出现 Cardiomyocyte、Epicardium、Valve（小鼠独有的词），预测侧出现 Atrial Cardiomyocyte、Mast cell、Mesothelial cell（人独有的词）。**两侧词表就是反的。**

第三步，旧代码怎么写的。 它把真值按**源物种**词表查、把预测按**目标物种**词表查——两边正好对调：

```python
```

错误写法（v1）

```
truth -> 源物种词表

pred  -> 目标物种词表
```

小结一句：跨物种评测里，查表用错物种 = 拿英语词典查法语单词。

3.3 查反了会怎样：两类样本被静默丢掉

第一类：真值查不到 → 直接跳过。 小鼠的 Cardiomyocyte 在人词表里查不到（人只有心房/心室两个亚型），于是这些细胞被 continue 掉，**在三种口径里全部消失**。人→鼠的分母就是这么从 1,535 掉到 1,309 的。

第二类：预测查不到 → 记为「不可映射」再丢一次。 人的 Atrial Cardiomyocyte 在小鼠词表里查不到，被当成「SATURN 输出了一个映射不了的类型」丢掉。

旧文档把这第二类现象解释成「SATURN 靠丢样本抬高分数」。**这个解释是错的**——丢样本不是 SATURN 的行为，是我们查表的副作用。而且真值侧丢得更多，这一点旧文档完全没提。

小结一句：一个 bug 制造了两类丢弃，其中一类还被误读成了方法本身的问题。

3.4 判定实验：四种约定，只有错的那种能复现旧值

光说「我们查反了」不够，得证明旧的数字确实是这样算出来的。做法：同一份混淆矩阵，用四种物种归属约定各算一遍 union macro-F1。

方向	冻结值（旧）	A 真值→源 / 预测→目标	B 真值→目标 / 预测→源	C 全源	D 全目标
人 → 鼠	0.4147	**0.4147**	0.3522	0.2980	0.3089
鼠 → 人	0.4010	**0.4010**	0.2566	0.3130	0.2714
人 → 斑马鱼	0.2479	**0.2479**	0.1269	0.1798	0.1418
斑马鱼 → 人	0.4021	**0.4021**	0.1640	0.1834	0.2512
鼠 → 斑马鱼	0.6500	**0.6500**	0.3658	0.3913	0.3718
斑马鱼 → 鼠	0.6510	**0.6510**	0.3563	0.3441	0.4602

A 复现 6/6，B/C/D 全部 0/6。 accuracy 交叉验证同样 6/6 命中 A（人→鼠 0.6241、鼠→斑马鱼 0.6863）。所以这不是「我们猜旧代码怎么写」，是**算出来的事实**。

复算脚本：scripts/convention_variants.py；结果 results/bootstrap-20261030/convention_variants.json。

小结一句：判定一个口径对不对，不看它顺不顺眼，看它能不能复现你手上的旧值。

3.5 修正后的数字，和「为什么仍算结论翻转」

修正后 SATURN 六向（results/bootstrap-20261030/saturn_convention_v2.json）：

方向	SATURN（修正后）	分母	旧值	虚高
人 → 鼠	0.3522	1505	0.4147	+0.0625
鼠 → 人	0.2566	1528	0.4010	+0.1444
人 → 斑马鱼	0.1269	1499	0.2479	+0.1210
斑马鱼 → 人	0.1640	1528	0.4021	+0.2381
鼠 → 斑马鱼	0.3658	1499	0.6500	+0.2842
斑马鱼 → 鼠	0.3563	1505	0.6510	+0.2947

三件事值得记住：

1. **SATURN 一个方向都不赢**。旧表里鼠↔鱼那两格 0.65，是 bug 造出来的。
2. **分母第一次一致了**（oPCA / scVI / SATURN 全部 1499–1528，差异只来自真值侧 unmapped 类）。跨方法比较第一次真正公平。
3. **推荐结论没变**：远缘四向仍首选 scVI。变的是理由——不再需要「SATURN 靠丢样本抬高分数」这套说法。

为什么仍然叫「结论翻转」：因为对外推荐从「鼠↔鱼用 SATURN」变成了「用 scVI」。**判断谁对错要改，理由可以换。** 但要如实说清：这次翻转的直接原因是我们自己的评测 bug，不是 SATURN 方法本身有缺陷。

小结一句：改了一个词表归属，六个数字全变，两个推荐翻转——评测实现的分量就是这么重。

第 4 章：三场景结论

先交代一条纪律：**我们不发布「总分」**。四个方法的**分母不完全相同**（oPCA 97–100%、scVI 97–100%、**SATURN 97–100%**（更正后）、SAMap 0–91%）、特征空间不同（9,018 个共同基因 vs 每方向独立的 15,869 / 9,311 / 8,160）、训练方式不同（每方向独立训练 vs 一次训练多方向评估）。把不同分母的分数平均起来，得到的是一个**加权错觉**——看着像个排名，其实是在平均几个不同问题的答案。所以结论只按场景分开说。

场景	关系	选谁	为什么
近缘	人 ↔ 鼠（同科，共享脊椎动物身体计划）	**ortholog-PCA 首选**，scVI 次选	两者统计上打平；oPCA 不需要 GPU、26.7 秒跑完、峰值内存 1.3 GB，代价低所以首选
远缘	鱼参与的四个方向（人↔斑马鱼、鼠↔斑马鱼，跨纲）	**scVI**	四个方向同细胞配对全部显著领先；「先按 1:1 直系同源把基因对上再 PCA」在基因对应关系变弱时损失太大
跨门	七鳃鳗 ↔ 小鼠（隔一个门）	**都不行**（负结果）	accuracy 4.6–5.8%，低于 13 类随机猜的 7.69%，macro-F1 连多数类基线都没超过

4.1 近缘：人 ↔ 鼠

什么物种对算这个场景：同科、共享同一套脊椎动物身体计划的两个物种，比如人 ↔ 鼠。我们门内用的是三物种心脏 scRNA 数据，每个物种 **1,528 / 1,535 / 1,543 个细胞**——规模很小，这是后面所有限定语的根源。

数字（回应稿 §1.2，每格是「方向 → 方向」两个方向）：

方法	人→鼠	鼠→人	两向均值
ortholog-PCA	0.6435	**0.6729**	0.6582
scVI	**0.6683**	0.5895	0.6289
SATURN	0.3522	0.2566	0.3044
SAMap	0.1127	0.0401	0.0764

为什么这么选：oPCA 与 scVI **基本打平**，方向间互有胜负——人→鼠 scVI 高 0.0247（配对 Δ=−0.0247，95% CI [−0.0639, +0.0134]，**不显著**），鼠→人 oPCA 高 0.0833（Δ=+0.0833，CI [+0.0386, +0.1238]，**显著**，3.8 SE）。

既然打平，**oPCA 的代价就成了决定性优势**：26.7 秒、纯 CPU、峰值内存 1.3 GB。一个例外：若下游还要拿**潜空间**去聚类或画 UMAP，scVI 的 batch-corrected latent（做过去批次效应的低维表示）更值得复用——这时选 scVI 不为分数，为那份表示。

顺带记一笔：SATURN 近缘只有 0.41，是 macrogene 压缩（把上万基因压到 1,000 维）在这个规模上有信息损失；SAMap 的图对齐在 1,500 细胞/物种下**根本没有可用信号**。

小结一句：近缘是「打平 + 选便宜的」，不是「有一个方法明显更强」。

4.2 远缘：鱼参与的四个方向

什么物种对算这个场景：同门不同纲，即人和鼠对上斑马鱼，四个方向（人→鱼、鱼→人、鼠→鱼、鱼→鼠）。

细胞规模差多少——这是本节最该盯住的地方：门内每物种 1,500 量级。**更正后**（2026-11-08）：oPCA / scVI / SATURN 的分母都在 **1,499–1,528**，差异只来自真值侧 unmapped 类；**SAMap 仍然只有 307–1,368**，在鱼→人、鼠↔鱼三个方向是 **n=0，无法评估**。也就是说，「SATURN 高分靠小分母」这个说法在更正后**不再成立**——它的小分母本身就是查表 bug 造成的；真正分母异常的是 SAMap。

方向	oPCA	scVI	SATURN（更正后）	分母	结论
人 → 斑马鱼	0.1654	**0.4014**	0.1269	1499	scVI 最优
斑马鱼 → 人	0.1512	**0.4290**	0.1640	1528	scVI 最优
鼠 → 斑马鱼	0.2177	**0.4248**	0.3658	1499	scVI 最优
斑马鱼 → 鼠	0.4405	**0.4786**	0.3563	1505	scVI 最优

> ⚠ 旧表里那两列「SATURN 旧口径 / 公平口径」（0.6500/0.4560 等）**已作废**。旧口径的 Δ 值（−0.2633 / −0.2005 / −0.1713 / −0.0709）是按错误分母算的，**重新配对检验前不要引用**；方向的定性结论不变（四向 scVI 最优）。

为什么选 scVI：

1. **oPCA 在远缘全面塌方**（0.1512–0.4405，四个方向里最低或次低）。原因很直白：「先用 1:1 直系同源把基因一对一接上、再做 PCA」这套做法，在基因对应关系本身变弱的时候，**第一步就把信息丢了**。
2. **scVI 是联合训练的潜空间方法**：两个物种一起进模型，让模型自己去找共享结构，而不是我们先替它规定「这个基因对那个基因」。
3. **SATURN 的领先是口径造出来的**，见第 3 章。

三条限定语必须随表出现：① 全部是 **transductive / in-sample**（评测用的细胞在训练时已经见过，衡量的是「同批数据上的标签迁移一致性」，**不是泛化能力**，不是留出评估）；② 分母不同，macro-F1 不能当绝对排名；③ 单看绝对分数，0.40–0.45 这一档本身不高，方向间 0.02–0.05 的细微差距**不应过度解读**。

小结一句：远缘的胜负不在「谁的特征工程更巧」，而在「谁能让模型自己学对齐」——所以 scVI 赢，而且四个方向都赢。

4.3 跨门：七鳃鳗 ↔ 小鼠 —— 为什么这是最差的一档

什么物种对算这个场景：不同门，隔着一整个门的距离，我们用七鳃鳗（Lamprey，无颌类）↔ 小鼠。数据是 LBSPA `8CrossSpecies.rds` 的 **Lamprey 41,678 + Mouse 14,016 个细胞**，基因轴 6,222 个（从 13,172 轴上取两物种 min_cells≥3 的共同基因），评估空间 **13 类交集，且只有 coarse 一层**。

数字（用可从混淆矩阵复现的那一组，见下方「待确认」）：

方向	方法	accuracy	macro-F1	多数类基线（acc / macro-F1）	13 类随机猜
七鳃鳗 → 小鼠	oPCA	0.0575	0.0235	0.2168 / 0.0274	0.0769
七鳃鳗 → 小鼠	scVI	0.0582	0.0241	0.2168 / 0.0274	0.0769
小鼠 → 七鳃鳗	oPCA	0.0516	0.0257	0.3059 / 0.0360	0.0769
小鼠 → 七鳃鳗	scVI	0.0457	0.0267	0.3059 / 0.0360	0.0769

为什么最差，三层原因：

1. **低于随机猜**。13 个类平均猜，命中率应该是 7.69%；实测 4.6–5.8%，**比闭眼乱猜还低**。这说明预测不是「随机不准」，而是**系统性地偏到某几个类上去了**——比随机更糟。
2. **离多数类基线差 4–6 倍**（0.0575 vs 0.2168，0.0457 vs 0.3059）。「全场都猜最多的那一类」这种零信息策略，能拿到 0.22–0.31 的 accuracy，我们两个方法都拿不到它的四分之一。
3. **macro-F1 连零信息基线都没超过**：0.0235 < 0.0274、0.0257 < 0.0360。这条最狠——它意味着这两个模型在这批数据上**提供的有效信息是负的**。

门内的优势没有延伸过来：门内人→斑马鱼，scVI 是 oPCA 的 2.4 倍（0.4014 vs 0.1654）；到跨门，两者一起塌到 0.06 量级，**彼此差距（0.0007–0.0059）远小于 bootstrap 的 SE，不构成差别**。所以「越远越要靠潜空间方法」这条规律，在跨门这一步**中断了**。

我们把这个负结果当成果写，因为它排除了一条路：跨门失败**不是「数据不够」或「方法没调好」**，而是当前这套「共同基因轴 + 单层细胞类型注释 + KNN 标签迁移」的范式在跨门尺度上不成立。

限定语（必须一起出现）：① Mouse 侧 **62.2% 的细胞被排除**（EX / IN / SNCG / Purkinje / Golgi / Bergmann 共 23,031 个）；② 基因轴是取交集，Lamprey 侧非零基因只占 56.7%；③ 只有 coarse 一层，与门内的三层评估**不对等**；④ 单 seed，无置信区间；⑤ **论断范围只能是**「在这套数据 / 注释 / 规模下跨门不成立」，不能断言跨门永远不可行。

小结一句：跨门不是「差一点」，是「低于随机、低于零信息基线」——这一档目前没有可用方法。

4.4 我们同时报两个口径，对外用公平口径

为什么两个都报：只报公平口径，等于把「SATURN 被抬高过」藏起来；只报旧口径，等于拿一个偏向 SATURN 的规则做跨方法比较。**两个都报并标出对外口径**，读的人才判断得出结论有多稳。

为什么对外用公平口径：因为**只有它和其他三个方法可比**。oPCA 和 scVI 的预测天然落在 coarse 空间内，不可映射率是 0——它们从没享受过「丢样本」的待遇。要让四个方法站在同一条起跑线上，唯一选择就是「保留全部细胞、不可映射的预测算错」。

代价也要说：公平口径对 SATURN **不利**（它就是被这条规则扣分的一方），所以不能既用它扣分、又不给解释。解释在第 3 章：SATURN 不是在「作弊」，是它的输出粒度天然比 coarse 细，而我们的评分空间是 coarse——**这是评价空间与模型输出空间不匹配，责任在评价设计，不在模型**。

一句话总结全篇：选方法之前先对齐口径，对齐口径之前先对齐分母；分母不同，分数之间没有可比性。

本篇标了「待确认」的地方

1. ~~两表打架~~ → ~~以 saturn_convention.json 为准~~ **再次更正（2026-11-08）**：saturn_convention.json（v1）本身是错的，**已作废**。现行以 saturn_convention_v2.json 为准：鼠→斑马鱼 **0.3658**（n=1499）、斑马鱼→鼠 **0.3563**（n=1505）。第 3、4 章已统一。
2. **跨门 macro-F1 有两个版本**：results/phase-20261022/crossphylum/metrics.json 存的旧值是 0.0711 / 0.0732 / 0.0652 / 0.0802，用同文件混淆矩阵重算得 0.0235 / 0.0257 / 0.0241 / 0.0267（差约 3 倍）。回应稿判定旧值**来源不明**，本轮统一用重算值——本篇第 4 章用的是重算值。选型指南 v6 的场景 3 表已在新版（v7）中改为重算值，**该冲突已解决**。
3. **人→斑马鱼、斑马鱼→人的配对 Δ（−0.2633 / −0.2005）标注为「现口径」**，回应稿未给 95% CI，也未说明是否已换成公平口径重算。本篇只引用 Δ 值，不给区间。
4. **SATURN 的 26.7 秒**（近缘 oPCA 耗时）与选型指南里的「30 秒（本地 6 方向）」是同一件事的两种表述口径（单方向 vs 六方向），本篇按回应稿写 26.7 秒。

第 5 章　为什么我们这么强调"可复现"

> 这一章只讲**为什么**。本项目最贵的一次翻车不是算错了，而是**算对了却说不清这份结果是从哪份代码、哪份数据跑出来的**。

5.1 sha256 冻结：给每个文件发一张"身份证"

sha256 是什么：把文件内容塞进一个公式，吐出一串 64 位十六进制字符串。改一个空格，这串字符就完全变样；反过来，字符串一样内容就一样。它当"指纹"用，不当"加密"用。

为什么每次跑完要记哈希："这份 predictions 是哪次跑出来的"只能靠哈希回答，不能靠文件名回答。哈希写进 sha256.tsv 就是发身份证——别人自己算一遍，和表里对上才算认领成功。

我们真踩过的 6 个坑

坑① 同一个文件名，不等于同一个文件。 平台上的 /Files/ResultData/Notebook/ortholog_pca_dcs_v3_fixkey.txt（17,382 B / 421 行 / json.loads 在第 167 行 / sha256 514d9314…）和本地的 scripts/ortholog_pca_dcs_v3_fixkey.py（16,463 B / 383 行 / csv.DictReader 在第 123 行 / sha256 f9683cf9…）**是两个不同的文件**。两者都有个 freeze_mapping 同名函数，但一个读 JSON、一个读 TSV。第一次在镜像里失败，就是把 TSV 喂给了读 JSON 那版，报 JSONDecodeError: Expecting value: line 1 column 1 (char 0)。光看名字你会以为"就是那个脚本"，一算 sha256 立刻知道不是。

坑② 靠计划文档推断"原件"，推错。 我们一度认定平台上的 samap_v98_emb.txt 是没打补丁的原件。下载回来一算：17,194 B / 422 行 / SHA 418ac586…，里面本来就有 EMB_SAVED 和 samap_joint_embedding.npy 的保存代码。计划文档会过期，平台上的文件才是事实。

坑③ 指标同名，算法不同版。 旧草表那组 80.9 / 38.3 / 40.5 / 22.4 / 11.9 / 79.5 已作废：一是排除规则失效（coarse_level=='unmapped' 一个都没命中，74 个该排除的细胞留在分母里），二是**评分器不是统一那版**（v75c/v78b 容器输出，与冻结的 KNN/置换定义有实现差异）。所以光锁数据不够，产出分数的**代码**也得锁。

坑④ 同一个 bug，两个版本号。 v98 的斑马鱼方向同源映射没取反（已修），冻结值是 19.61 / 27.55；修正后 FIXKEY 权威值是 17.95 / 26.75。人↔鼠两向两口径相同（86.18 / 73.69）。所以数字必须带版本名，裸数字等于没信息。

坑⑤ 哈希相同，不代表内容对。 平台那一页的 headless 截图被合成器缓存——连续三张截图 sha256 **完全相同**，而 DOM 已经更新。哈希只证明"两次拿到的东西一样"，不证明"这个东西对"。取证以 DOM 为准。

坑⑥ 手写数字必错。 report-03 里六方向均值按印象写成 0.4988 / 0.4200 / 0.3922，实际是 0.4986 / 0.4611 / 0.3857（SAMap 0.0334）。所有表格数字必须从 metrics.json 用脚本生成。

5.2 环境记录：证明"在哪跑出来的"

为什么存：一个分数只在特定环境里成立。environment.txt 记三件事：**跑在哪个平台、什么包版本、什么镜像**。实测跑通的组合是 python 3.9 / numpy 1.23.5 / scipy 1.10.1 / pandas 1.5.3 / scikit-learn 1.6.1 / anndata 0.10.8 / scanpy 1.9.3 / h5py 3.8.0 / scvi-tools 1.1.6.post2 / torch 2.6.0+cu124。

一个反直觉的结论：本地 scipy 1.12.0 / pandas 2.3.3 / anndata 0.10.9 跟锁的版本**都不一样**，6 个冻结值仍 100% 复现。也就是说——**锁版本是为了"可复现"，不是为了"算得对"**。

镜像要单独记，因为平台镜像是"**基础镜像 + pip 包清单**"，跟 Dockerfile 是两套机制。构建成功的是 g5-opca-container（2026-10-30）。另纠正一个错判：文档里一度都写"平台镜像构建通道失败"，实际数了一遍，5 次尝试里有 1 次成功（g5-canary-pinned，2026-09-21 20:43，基于 SATURN--22），system 的 centos-7、zhongliyuan 的 SATURN--22 也成功了——**通道可用，失败集中在 SAMap/kBET 那种复杂依赖上**。"失败过"不等于"不能用"。

5.3 产物目录结构：每个文件各管一件事

以镜像内那次跑为例，产物目录是 /work/user50719-8334/opca-full-20261031T115728Z/：

文件/目录	管什么	为什么非它不可
metrics.json	分数本体（accuracy、macro-F1、SE/CI）	唯一"官方数字"来源，表格一律从这里生成
predictions/	逐细胞预测	**唯一能换口径重算的东西**。18 份逐细胞预测独立重算，才有 union 口径的权威数字表
confusion/	混淆矩阵	别人能独立验的最小证据。跨门 macro-F1 改成 0.0235–0.0267，就是因为这个区间**能从混淆矩阵复现**
manifest.json	这次跑用了哪些输入、参数、版本	回答"谁、用什么生成的"，含 script_sha256 / mapping_sha256
sha256.tsv	每个产物的哈希	防篡改、防同名混淆（见坑①）
environment.txt	环境快照	回答"在哪跑出来的"（见 5.2）

为什么拆这么细：metrics.json 只给结论，predictions/ 和 confusion/ 给"别人能不能自己算一遍"。只交前者等于只交答案，别人只能信你。

> 待确认：manifest.json 与 environment.txt 的具体字段清单，素材只记了"含哪些"，未逐字段列出。

5.4 为什么"能复现"比"分数高"更重要

因为高分是别人的，能复现才是自己的。 四个真实取舍：

1. **86.18% 再高，签字前也不能当结论。** 它的基础是 `config/heart-celltype-map-v1.tsv`（38 行、35 个 active、3 个 unmapped），`reviewer` 列**全是 pending**。这张表决定分母里装谁，按纪律要导师签字才能从 `needs-reviewer` 改成 `confirmed`。
2. **我们主动把数字改难看了。** 跨门 macro-F1 旧存值 0.0652–0.0802 **来源不明**（accuracy 与混淆矩阵完全一致，macro-F1 却差约 3 倍），换成可从混淆矩阵复现的 0.0235–0.0267。换完负结果更强：两个方法都低于多数类基线（0.0235 < 0.0274、0.0257 < 0.0360）。
3. **能复现才敢改结论。** SATURN 全列在 2026-11-08 被重算：根因是评测把**真值按源物种词表、预测按目标物种词表**查表（颠倒），两侧各丢一批细胞。修正后六向 0.3522 / 0.2566 / 0.1269 / 0.1640 / 0.3658 / 0.3563，一个方向都不赢。结论从"SATURN 首选"改成"scVI 首选"，**但理由是纠错，不是换口径**。见 `docs/reports/report-09-corrections-20261108.md`。
4. **最高形态是逐位复现。** 2026-10-31，任务 `2116497194053881858` 在 `g5-opca-container` 里跑通完整评估，**6 个冻结 coarse accuracy 逐位复现（6/6）**。日志里有 `script_sha256`、`mapping_sha256`、`ortholog pairs: hm=17611 fh=10398 fmm=9058`，最后 `DONE`。

一句话总结：**分数会被质疑，哈希和目录结构不会。**

第 6 章　组员最容易问的 10 个问题（FAQ）

Q1　SATURN 是不是没用？

一句话答：不是没用，是它原来的分数被我们评测实现里的一个查表 bug 抬高了；修正后它明显落后，但那是"在这套数据上"的结论。

详细说：旧算法把真值按源物种词表查、预测按目标物种词表查，方向反了，导致真值侧查不到的被跳过、预测侧查不到的被判成不可映射，两侧都少了一批细胞。修正后鼠→斑马鱼 0.3658、斑马鱼→鼠 0.3563，两向都落后 scVI。但要分清：这是**我们的评测实现**有 bug，不是 SATURN 方法本身被证伪——换个数据集、换成留出评估，结论可能不同。它在批次混合那栏缺席，是重训会造出"同一方法的两个版本"这种假对照，不是没做。

Q2　为什么我们的数字和别人论文里不一样？

一句话答：口径不同，一共六处，每一处都能让数字变。

详细说：① union 还是 truth-only（见 Q8）；② 分母不同，oPCA 1499–1528、scVI 1499–1528、SATURN 1499–1528、SAMap 307–1368；③ 我们是 transductive / in-sample，不是留出评估；④ 规模差 约 104 倍，原文用完整图谱，我们每物种约 1,500 细胞；⑤ 只喂一对一同源基因（人鼠 15,869 / 人鱼 9,311 / 鼠鱼 8,160），原文用含 many-to-many 的全同源图；⑥ 同源来源不同，原文用 BLASTP 建图，我们用现成直系同源表。引用任何数，必须连口径一起说。

Q3　oPCA 这么快，为什么不全都用它?

一句话答：门内它已经明显落后，跨门它和 scVI 一起塌，快不等于够用。

详细说：门内人→鱼时 scVI 是 oPCA 的 2.4 倍（0.4014 对 0.1654，FIXKEY 口径）。到跨门两者一起掉到 0.05 量级，没有实质差别。它的价值在"近缘、要快、要能解释"的场景，不在"跨得远还要准"。

Q4　86.18% 这个数是怎么来的? 为什么说它"依赖未签认的映射表"?

一句话答：它是人→鼠 coarse accuracy 的 FIXKEY 口径值，前提是一张没人签过字的细胞类型映射表。

详细说：这张表是 config/heart-celltype-map-v1.tsv，38 行、35 个 active、3 个 unmapped，reviewer 列**全是 pending**。它决定哪些细胞类型参与评估，也就是决定分母里装谁；分母一变，86.18% 就变。所以签字前只能标 needs-reviewer，不能当结论引用。

Q5　什么叫"算得对"不等于"分得对"?

一句话答：accuracy 高只说明多数类猜中了，macro-F1 才看每个类有没有被分开。

详细说：跨门那次 accuracy 和混淆矩阵完全一致，但旧存值 macro-F1 比可复现值高约 3 倍（0.0652–0.0802 对 0.0235–0.0267）。换口径后两个方法都低于多数类基线（0.0235 < 0.0274、0.0257 < 0.0360）。反过来也有：三个方法 iLISI 只有 1.006–1.120（满值 3），看着像全失败，但同一份 scVI 潜空间上人→鼠 macro-F1 有 0.6683。

Q6　跨门为什么效果这么差? 是不是方法不行?

一句话答：不是方法不行，是"越远越靠潜空间"这个规律在跨门这一步断了。

详细说：门内人→鱼时 scVI 还是 oPCA 的 2.4 倍，到跨门两者一起塌到 0.05 量级，谁也没优势。所以这是我们这个规模下的负结果，不是判决书。三条限定语必须随数字出现：全部是 transductive、四个方法分母不同、"不推荐"不等于"方法差"。

Q7　平台标"失败"的任务是真的失败吗?

一句话答：不是，至少有一次它其实跑成功了，只是最后一行命令报错。

详细说：任务 2116497194053881858 平台标失败，实际 6 个冻结 coarse accuracy 逐位复现（6/6）。原因是 fixkey.sh 最后一步 cat $OPCA_OUT/metrics.json，而脚本读的变量是 OPCA_OUT_ROOT，cat 找不到文件、退出码非 0，产物其实已经写好了。同类还有一次：samap_v98_emb.txt 报"上传失败"，文件早就在 /Files/ResultData/Notebook/ 里。**别人说失败，要用独立证据复核。**

Q8 为什么要同时报两个口径？只报公平口径不行吗？

一句话答：行，但你必须说清用的是哪个，否则别人对不上号。

详细说：两个口径是 truth-only（只按真实标签集平均，平台 scVI 脚本默认）和 union（真实∪预测一起平均，多预测的类记 F1=0）。实例：人→斑马鱼 coarse，truth-only 0.4516、union 0.4014，差 0.05 就够翻转结论。跨方法比较一律用 union，且从逐细胞预测独立重算。单独看 truth-only 不算错，错在把它和别的方法并列。

Q9 老师七条意见我们到底怎么落的？

一句话答：一条一句，全落在报告和数字里了。

- **一、近缘/远缘/跨门分开说**：不给总分冠军，改成"场景→推荐谁"的选型表。
- **二、百分数要带稳定性**：每个分数配 ±bootstrap SE 与 95% CI（22 行全表在 results/bootstrap-20261030/bootstrap.json）。
- **三、结论和原文不一样要说清**：列了三条原因（规模差 约 104 倍、只喂 1:1 同源、同源来源不同），并自查出 SATURN 口径抬高。
- **四、实际消耗**：平台任务台账 + 本地白盒测量都出表了。
- **五、流程要有名字**：定为 XenoTransfer v1.0。
- **六、GitHub / DCS**：仓库在但推不上去（临时文件、凭据核查、LICENSE 未清）；DCS 可以发但没发。
- **七、新增实验与产物**：镜像构建成功 + 镜像内 6 个冻结值逐位复现，产物可复核。

Q10 我想自己跑一遍，从哪开始？

一句话答：别从零搭，从已经跑通的那条路复制。

详细说：流程用 2026-10-05 跑通过的 runsamap（5 个输入：三份 h5ad + 脚本 + pylibs），不要用只声明 2 个输入的那版。镜像用 g5-opca-container，container/entrypoint.sh 现在导出 7 个变量，脚本读几个就得导几个。import 报错别猜，做二分测试（先 torch、再 anndata、最后 scvi），解压 pylibs 后先 rm -rf ./pylibs_full/anndata ./pylibs_full/anndata-*.dist-info。页面下拉恒"无数据"时用 dcs task run 投递绕开。跑完把 predictions/、confusion/、manifest.json、sha256.tsv、environment.txt 一起收走。