课题 5 组员说明：我们干了什么、上台讲什么（小白版）

> 写给**完全没参与过、也没学过单细胞分析**的组员。 读完你应该能做到三件事：①用一分钟说清这个项目在做什么；②看懂任何一张结果表；③知道哪些话能说、哪些话千万别说。 全文不需要任何生信背景，遇到术语我都在括号里解释。

第 0 章：先用一分钟说清这个项目

0.1 一句话版本

> **我们测了四种"把细胞类型从一个物种搬到另一个物种"的方法，看哪种在什么场景下靠谱，最后给出一张"什么情况用哪个"的选型表。**

0.2 为什么会有这个问题（打个比方）

假设你有一本**人的细胞图鉴**（每个细胞都标好了类型：心肌、内皮、免疫……），现在拿到一批**小鼠**的细胞，但没人给小鼠标过。

问题：能不能**拿人的图鉴去推小鼠的细胞类型**？

这就是"跨物种标签迁移"。人和小鼠还好办（都是哺乳动物，基因能一一对上）；但如果换成人和**斑马鱼**（隔了几亿年），或者更远的**七鳃鳗**（连"门"都不一样了），还能不能推？

我们的任务是：把四种方法都试一遍，看谁在近缘（人↔鼠）、远缘（人↔鱼）、跨门（七鳃鳗↔鼠）三种情况下靠得住。

0.3 课程要我们交什么

课程要求	我们交了
基准测试报告	course5-final-report-v2-20261023.docx
场景化选型指南（核心）	场景化选型指南-v8-20261109.md
至少覆盖近缘 / 跨门 / 无 GPU	三个场景都做了实验
批次混合与生物保守性	三项指标，三个方法并表
时间和内存	平台台账 + 本地实测
容器化	配方 + 平台镜像 + 镜像内复现
七次汇报材料	已有 1–3 次 + 对外版 v2
AI 使用日志	docs/ai-use-log.tsv

第 1 章：四种方法，用大白话讲

不用记全名，记「它靠什么」就行。

方法	一句话	打个比方	代价
ortholog-PCA（我们叫 oPCA）	把两个物种压到**同一批一一对应的基因**上，再做降维，然后按"谁跟谁最像"投票	只拿两本书**共有的词**做对照表	27 秒，纯 CPU，内存 1.3 GB。**最快最省**
SATURN	把基因翻译成**蛋白质语言**（用 ESM2 模型），压成"宏基因"再对齐	不查词了，改看**意思**像不像	要 GPU 训练，部署最麻烦
SAMap	建两个物种基因的**同源关系图**，按图找对应	画一张两族人的**族谱**再对	依赖最多，最不稳定
scVI	生成模型，把多物种细胞**一起训练**到一个低维空间	让大家住进**同一个小区**，再按邻居判断	要训练，但 CPU 8.5 分钟就够（不用 GPU）

1.1 一个反直觉的发现（这个值得讲）

"深度学习必须用 GPU"在这套数据上不成立。 scVI 是深度生成模型，但 4,606 个细胞、9,018 个基因这个规模，**CPU 8.5 分钟**就跑完了（平台 2 核实测含 IO 15 分 16 秒）。

1.2 为什么还留了一个"土办法"当基线

oPCA 就是那个土办法。留它的理由很实际：**任何复杂方法都得先证明自己打得过它，否则不值得用。**结果它还真赢了一个方向（鼠→人），而且只用 27 秒。

第 2 章：数据长什么样（数字要能背下来）

项	数字	说明
门内三个物种	人 **1,528** / 小鼠 **1,535** / 斑马鱼 **1,543** 细胞	合计 **4,606** 个细胞。很少，这是所有限定语的根源
基因数	各物种 27,519–32,732 个	
一一对应基因（1:1 同源）	人鼠 **15,869** 对 / 人鱼 **9,311** / 鼠鱼 **8,160**	两个物种都有、且能一一对上的基因
跨门数据	七鳃鳗 **41,678** + 小鼠 **14,016** = 55,694 细胞	共同基因轴 6,222

项	数字	说明
标签层级	exact（原始注释）/ **coarse**（粗类 9–10 类）/ fine（细类）	我们主要用 coarse

为什么 4,606 这个数字要背下来：因为每次讲结论都要带一句"这是在这个规模上测的"。数据一大，结论可能变。

第 3 章：怎么看懂结果表（这章最重要）

3.1 主指标：macro-F1 是什么

先讲 **accuracy（准确率）**：对了几个 ÷ 总共几个。

问题：如果 80% 的细胞都是同一种类型，那我**闭着眼睛全猜那一种**，准确率也有 80%。这叫"被多数类绑架"。

macro-F1 怎么解决：先给**每个细胞类型各算一个** F1 分数，再把它们**等权平均。**

> 好比考试不只算总分，还要看每一科。你数学 100 分、语文 0 分，总分可能还行，但"每科平均"会把你拉下来。

一个真实数字：人→鼠这个方向，多数类基线的 accuracy 有 **48.17%**，但它的 macro-F1 只有 **0.0813** ——因为它只对一个类好。这就是为什么课程要求用 macro-F1。

3.2 报分必须带三个东西（少一个就是耍流氓）

要带的	是什么	为什么必须带
分母 n_q	有多少个细胞真正参加了评分	排除规则一改，分母就变，同一个分子能算出不同的百分比
majority	最大真值类的占比（无信息基线）	防止"看着高其实全靠猜"
union 口径	真实标签 ∪ 预测标签一起平均	预测出"真值里没有的类"要记 0 分，不能假装不存在

举个能记住的例子：人→鼠

- 输入：人 1,528（有答案，当参考书）/ 鼠 1,535（要预测，当卷子）
- 排除：剔掉 30 个（鼠侧标记状态不是 active 的）
- **分母 = 1,505**
- **分子 = 1,297**
- **accuracy = 1,297 ÷ 1,505 = 86.18%** ← 这个数字我们引用过很多次

关键：分母是"有资格参加考试的细胞"，不是全部 1,535。规则一改，分母就变，同样的 1,297 会算出不同百分比。

3.3 我们的结果表怎么读

现行主表（coarse macro-F1，union 口径，strict_cell）：

方向	oPCA	scVI	SATURN	SAMap
人→鼠	0.6435	**0.6683**	0.3522	0.1127
鼠→人	**0.6729**	0.5895	0.2566	0.0401
人→斑马鱼	0.1506	**0.4014**	0.1282	0.0477
斑马鱼→人	0.2131	**0.4290**	0.1386	n/a
鼠→斑马鱼	0.2816	**0.4248**	0.4076	n/a
斑马鱼→鼠	0.4186	**0.4786**	0.2961	n/a

三句话读完这张表：

1. **每一行加粗的就是这行最好的。**六行里五行是 scVI，一行是 oPCA。
2. **n/a 表示这个方向没细胞能对上**，不是"0 分"，是"没法评"。
3. **不要跨行比。**人→鼠 0.67 跟 人→斑马鱼 0.40 不能直接说"前者更容易"就完事 —— 难度本来就不同。

第 4 章：我们踩的两个大坑（这是加分项）

主动讲坑，比只讲成绩更让人信。 而且这两个坑是我们自己查出来的。

4.1 坑一：一个查表方向搞反，让 SATURN 虚高了 0.06–0.35

背景：每个物种的细胞类型是**各自一套词。**

- 人会说 Ventricular Cardiomyocyte（心室肌）和 Atrial Cardiomyocyte（心房肌）
- 小鼠只说 Cardiomyocyte（不分房室）
- 斑马鱼里甚至有个 Orthers —— 那是 Others 的拼写错误，意思是"其他"

规则：跨物种迁移时

- **真值**（答案）用 **目标物种**的词表 ← 因为那是被预测那方的真实注释
- **预测**用 **源物种**的词表 ← 因为方法是拿参考书那方的类型名去输出

我们错在哪：旧代码把两边**正好对调**了。

后果一：真值查不到 → 直接跳过。小鼠的 Cardiomyocyte 在人词表里不存在，这些细胞**静默消失**。人→鼠的分母从 1,535 掉到 1,309。

后果二：预测查不到 → 记成"不可映射"再丢一次。人的 Atrial Cardiomyocyte 在小鼠词表里不存在，被当成"方法输出不了"丢掉。

我们怎么证明是这么错的：拿同一份混淆矩阵，用四种查表约定各算一遍：

方向	旧值	错的那种（我们用的）	正确方向
人→鼠	0.4147	**0.4147**（完全对上）	0.3522
鼠→斑马鱼	0.6500	**0.6500**（完全对上）	0.4076

只有错的那种能复现全部旧值（6/6），准确率也 6/6 对上。所以这不是"猜旧代码怎么写"，是**算出来的事实。**

修正后：SATURN 从 0.6500 掉到 0.4076，**一个方向都不赢。**

> **讲话注意**：这是**我们自己评测实现的问题**，不是 SATURN 论文的错。说错方向会显得不专业。

4.2 坑二：映射表里有个"其他"被当成了"神经"

映射表（38 行）规定"哪个原始标签算哪个粗类"。其中三行有问题：

行	原始标签	原来归到	问题
斑马鱼 Orthers	拼写错误的"其他"	neural（神经）	把"无法归类"硬算成神经。**注意：这一行只有 30 个细胞**
小鼠 Valve（瓣膜）		fibroblast（成纤维）	可辩护，但是建模选择，要标注
斑马鱼 Perivascular cells（血管周细胞）		smooth_muscle（平滑肌）	同样要标注

我们怎么处理：Orthers 直接**退出评估**；另两行保留，但写清"依据 / 备选归类 / 预期偏差方向 / 敏感性结果"四项。

顺带纠正一个流传的错误说法：旧文档里写的"865 个细胞的错误归属"不准确。865 是**预测时被判断成 Orthers 的细胞数**，不是这一行误分类的真值细胞数（真值侧只有 30 个）。

4.3 坑三（方法论）：只要表里有"不可映射"的类，丢样本就会抬高分数

Orthers 退出评估后，斑马鱼→人这个方向又出现了"丢样本"现象。

两种口径：

- published（丢样本）：只算"预测恰好能对上"的细胞 → 斑马鱼→人 = **0.2501**

- strict_cell（保留细胞、对不上算错）→ **0.1386**

差 0.11，足以改变"有没有信号"的判断。所以对外一律用 strict_cell。

第 5 章：三条硬结论（背这三句就够）

1. 没有全面赢家。 所以不排总分冠军，只做"场景 → 方法"的选型表。

2. 近缘用最简单的就够了。 人↔鼠上 oPCA 和 scVI 基本打平（两向均值 0.6582 vs 0.6289），而 oPCA 只要 27 秒、不用 GPU。

3. 跨门，这一族方法都做不了。 七鳃鳗↔小鼠准确率 4.6–5.8%，比随机猜（约 7.7%）还低，macro-F1 连多数类基线都没超过。**这是有价值的负结果，不是失败。**

第 6 章：上台怎么讲（三段现成稿子）

6.1 三分钟版（组会/随堂）

> "我们做的是一件事：**测四种'跨物种细胞类型迁移'方法，看哪种在什么场景下靠谱。** 数据是三个物种的心脏单细胞，人 1,528、小鼠 1,535、斑马鱼 1,543，一共 4,606 个细胞；另外用七鳃鳗和小鼠的脑数据做跨门测试。 四个方法：oPCA 是快速基线，27 秒、不用 GPU；scVI 是深度生成模型；SATURN 用蛋白质语言对齐；SAMap 走同源基因图。 结论三条：**没有全面赢家**，所以不做总分排名，只做选型表；**近缘用 oPCA 就够**；**跨门这一族方法都做不了**，准确率比随机猜还低。 过程中我们自己查出两个错并修正：一个是评测时把物种词表查反了，让 SATURN 虚高 0.06 到 0.35；一个是映射表把一个'其他'类别当成了神经。这两处都重算并写进更正报告。"

6.2 五分钟版（多讲数字和方法）

在三分钟版基础上加：

- **主指标为什么用 macro-F1**：多数类基线准确率 48.17% 但 macro-F1 只有 0.0813，accuracy 会被大类绑架。
- **一个数字怎么来的**：人→鼠，分母 1,505、分子 1,297、86.18%。
- **批次混合**：三个方法都没把物种混匀（iLISI 1.006–1.120，满值 3）；但**低 iLISI 不等于方法失败** ——同一份 scVI 潜空间上人→鼠 macro-F1 有 0.6683，两组证据必须一起报。
- **可复现**：平台镜像 g5-opca-container 构建成功，镜像内 6 个冻结值逐位复现 6/6。

6.3 答辩版（被追问时用）

- **凭什么说跨门不行**：13 类空间随机猜约 7.7%，我们实测 4.6–5.8%，**低于随机**；macro-F1（0.0235–0.0267）也低于多数类基线（0.0274 / 0.0360）。
- **为什么不排冠军**：四个方法的**分母不同、特征空间不同、训练方式不同、统计强度不同**，平均起来是加权错觉。
- **SATURN 为什么没有批次指标**：产物已清理、ESM2 嵌入不存在，重训会产出**不同的表示**，并表就是假对照。所以标 not measured，不半补。

第 7 章：十个最可能被问到的问题

Q1：你们的数据是不是太少了？ 是。4,606 个细胞、三个物种、一个心脏数据集。所以所有结论都限定在"这个规模"上，不推广。

Q2：为什么不用 accuracy？ 会被多数类绑架。人→鼠多数类基线准确率 48.17%，macro-F1 只有 0.0813。

Q3：SATURN 是不是很差？ 不能说"差"。它在我们这套数据、这个规模下、按正确口径算是排在后面；换数据集可能不同。而且它需要 GPU，我们只有一次训练。

Q4：为什么 SATURN 和其它方法的分数差这么多？ 一部分是方法本身，一部分是我们修正了评测 bug（见第 4 章）。修正后它确实落后。

Q5：你们的结果能复现吗？ 能到"镜像内 6 个冻结值逐位复现 6/6"，日志里有 script_sha256、mapping_sha256。但 docker build 本机没跑成（没有 WSL 发行版），这是唯一没做的一步。

Q6：为什么有 n/a？ 那个方向没有任何细胞能对上，不是 0 分，是"无法评估"。

Q7：3.2 里那个 86.18% 是怎么算的？ 1,297 ÷ 1,505。分母是"有资格参加评估的细胞"，不是全部 1,535。

Q8：你们有没有作弊？ 反过来，**我们主动把数字改难看了两次**：一次是跨门 macro-F1 从 0.0652–0.0802 改成可复现的 0.0235–0.0267；一次是这次把 SATURN 从 0.65 改到 0.41。

Q9：映射表是谁定的？ 我们自己按文献定的 38 行，reviewer 列原来是 pending。2026-11-09 完成签认：30 行 canonical、5 行"已披露的建模选择"、3 行排除类。**要投稿的话建议再找生物学同行抽查 20%。**

Q10：这个项目最大的价值是什么？ 不是"哪个方法最好"，而是**证明了"排名对评测实现极其敏感"**：改一个查表方向，六个数字全变、两个推荐翻转。这比任何一个分数都值得记住。

第 8 章：绝对不能说错的话（红线）

× 不能说	○ 应该说
"SATURN 论文有问题"	"**我们的评测实现**里存在词表归属错误"
"我们证明了 SATURN 不行"	"**在这套数据、这个规模下** SATURN 排在后面"
"SAMap 是垃圾"	"SAMap 在 1,500 细胞 + 1:1 同源约束下**无可用信号**"
"这是留出评估 / 泛化能力"	"这是 **transductive / in-sample**，同批数据重评估"
"scVI 最好"	"**远缘场景首选 scVI**，近缘 oPCA 更划算"
只报一个分数	必须带「**union 口径 + 分母 n_q + strict_cell**」

第 9 章：谁负责什么（汇报分工建议）

部分	建议谁讲	理由
项目背景 + 三个场景	谁都行	背第 0 章就够
四种方法原理	讲得清比喻的人	第 1 章的比喻照念
数字怎么算的	细心的那个	第 3 章 3.2 的拆解要能默写
两个坑与更正	**最了解过程的人**	这章最能体现工作量
跨门负结果	能扛住追问的人	第 6.3 节准备好
可复现与容器	跑过命令的人	被问 docker build 要如实说没跑成

第 10 章：术语小词典（被问到就查）

术语	人话
单细胞测序（scRNA）	把组织拆成一个个细胞，逐个读它表达了哪些基因
coarse / fine 标签	粗类（9–10 类，如"心肌"）/ 细类（如"心室肌"）
1:1 同源基因	两个物种里能一一对上的基因
macro-F1	每类各算 F1 再等权平均，不被大类绑架
union 口径	真实 ∪ 预测一起参与平均，预测出真值里没有的类记 0 分
n_q	进入分母的细胞数
bootstrap 置信区间	把样本反复重抽样，看结论稳不稳
transductive / in-sample	评估时数据里已经包含待预测的细胞（不是留出评估）
iLISI / kBET / silhouette	三个批次混合指标：混得匀不匀、保不保类型
多数类基线	全场都猜最多的那一类，作为"无信息"的对照
SATURN / SAMap / scVI	三种跨物种整合方法（见第 1 章）

附录 A：所有文件的正式名字

用途	文件
课程核心交付物	deliverables/场景化选型指南-v8-20261109.md
对外汇报 PPT	results/stage-reports-20261102/课题 5-三场景结论与可复现闭环-v2-20261109.pptx
基准测试报告	deliverables/course5-final-report-v2-20261023.docx
技术总交接	deliverables/课题 5-总交接文档-20261028.docx
更正报告（词表方向）	docs/reports/report-09-corrections-20261108.md
更正报告（映射表）	docs/reports/report-11-mapping-signoff-20261109.md
全流程复盘	docs/reports/report-12-full-recap-20261110.md
哪些文件还能引	docs/execution/20261108-更正索引.md
踩坑清单 33 条	deliverables/课题 5-踩坑清单-20261030.docx

附录 B：仓库地址

https://github.com/bernis-web/course5-prep

```
git clone -b share-deliverables-20261104 https://github.com/bernis-web/course5-prep.git
```

> 注意： 必须带 -b share-deliverables-20261104。默认分支已经是它，但 main 是 9 月的旧版本，里面什么都没有。

附录 C：三句话总结（如果只能记三句）

1. **我们的百分比不是抄的**，是八道工序算出来的（原始数据 → 归一化 → 同源基因 → 降维 → 找邻居 → 投票 → 算分 → 存档）。换任何一道工序的定义，数字就会变。
2. **没有全面赢家**，所以不排总分，只做"场景 → 方法"的选型表。
3. **所有结论都限定在 transductive / in-sample、4,606 个细胞**；而且我们主动改难过两次数字，两次都留了更正报告。