课题 5 第 2 次汇报（第 2/7 次）

数字来源链：一个百分比是怎么来的

配套 PPT：results/stage-reports-20261019/课题 5 第 02 次汇报_数字来源链_校模板.pptx（9 页，7 分 55 秒）

口径：全部 transductive / in-sample；单 seed（0）；K=15 cosine 倒距离加权 | 日期：2026-10-19

汇报节奏

页	内容	建议用时
1	封面	10 秒
2	任务定位与进度	45 秒
3	老师反馈与本次调整	55 秒
4	来源链八环节	60 秒
5	86.18% 拆解	80 秒
6	分母与四个量	60 秒
7	macro-F1 两种口径	55 秒
8	四方法结果	50 秒
9	选型指南 v0	60 秒

合计约 7 分 55 秒。

第 1 页 · 封面

标题：课题 5 第 2 次汇报：数字来源链

副标题：一个百分比是怎么来的 —— 从原始细胞到表格单元格的可复核路径

口播

这次不讲新结果，讲现有数字是怎么来的。

第 2 页 · 任务定位：本次讲的是哪一块

顶部先给课程原题：跨物种单细胞整合：SATURN vs SAMap vs scVI 系的基准测试与场景化选型。

课程要求	状态
四方法对比（含自建 oPCA 基线）	已完成
主指标 macro-F1（统一口径）	已完成
场景：近缘 + 无 GPU	已完成
批次混合与生物保守性	进行中（scVI 已测）
时间与内存	进行中（scVI 已测）
场景：跨门（七鳃鳗 ↔ 鼠）	未开始（数据已定位）
文档 / Agent 友好度 + 容器化	未开始

进度：3 / 7 完成，2 项进行中，2 项未开始。

本次覆盖：第 2 项「主指标」的底层——一个百分比是怎么算出来的。

下次覆盖第 1 项与第 6 项的边界问题：为什么不能排冠军。

口播提示

这页只花 45 秒，作用是让老师立刻知道“现在讲到任务的哪一块、整体到哪一步”，后面就不用每页再解释上下文。

第 3 页 · 老师反馈之后：先改交付物类型

- 老师说的「偏」：不是数字不准，而是整份材料回答错了问题——在讲“证据可不可信”，没讲“哪个方法该在什么场景用”。
- 根因：交付物类型错了。课程要的是「场景 → 方法 → 指标 → 选型」的基准报告，我们交的是审计报告。
- 本次怎么改：保留证据链（它是对的），但把它从“全部篇幅”降为“支撑材料”；主线回到方法与场景。

收束句：本次先补上“数字怎么来的”这一层，把可信度做成可复核的底子；下一次再讲“为什么不能排冠军”。

口播提示

这页要快，不要自我检讨太久；重点是“改了什么”，不是“错在哪”。

第 4 页 · 从原始细胞到表格单元格：八个环节

#	环节	落盘物
1	原始 h5ad	三物种心脏单细胞
2	归一化	normalize_total(1e4) + log1p
3	表示层	同源交集 + PCA-50
4	角色划分	src = reference，tgt = query
5	KNN15	cosine，倒距离加权
6	逐细胞预测	含 confidence 与排除原因
7	排除与计数	correct / eligible = n_q
8	metrics.json	SHA-256 锚定

核心句：换掉任何一环的定义，最终百分比就会变——所以复核必须沿这条链走，而不是从表里抄数。

补充：每一环都有落盘物，第三方可以据此重算任意一个单元格。

第 5 页 · 实例拆解：86.18% = 1,297 ÷ 1,505

环节	内容	取值
输入	reference = 人 ｜ query = 鼠	1,528 / 1,535
同源基因	人鼠 1:1 直系同源交集	15,869
表示层	人+鼠联合 PCA-50（seed 0）	3,063 × 50
评分	KNN15，cosine，倒距离加权	k = 15
排除	鼠侧 status ≠ active	剔 30
eligible query	1,535 − 30	n_q = 1,505
正确数	逐细胞预测 == 真值	1,297

核心句：86.18% = 正确预测数 ÷ 排除后仍有资格的 query 细胞。不是从表里抄出来的。

逐类分解（confusion 摘录）：内皮 720/725、成纤维 255/360、免疫 197/202、心肌 19/47；错误集中在成纤维→平滑肌（82）与心肌→内皮（27）。

主源：results/pilot-v1/ortholog-pca-v98/metrics.json，SHA b2b3ac6b…c725，本地已独立复算。

第 6 页 · 分母会变，所以必须一起报

同一个 coarse 层，query 细胞 1,535 个，排除 30 个后不再进入分母。eligible 1,505，coverage 98.05%。

必须并列报的量	定义	为什么必须报
accuracy	correct ÷ n_q	主指标
n_q / coverage	进入分母的细胞数	排除规则一改，分母就变
majority	最大真值类占比	无信息基线：准确率 0.4817，macro-F1 仅 0.0813
shuffle_p	预测向量置换检验	只回答“是否优于随机”，不是多数类检验

核心句：只报 accuracy，等于把分母的变化藏起来。

第 7 页 · 同一份预测，两个 macro-F1

- truth-only（平台 scVI 脚本默认）：0.4516 —— 只按真实标签集取平均；预测多出来的类被忽略。
- union（本项目跨方法统一口径）：0.4014 —— 真实 ∪ 预测一起取平均；预测多出来的类记 F1 = 0。

差值来源：被预测出来、但真值里根本不存在的类。这类越多，两个口径差得越大。

核心句：单独看 truth-only 没问题，但它不能和别的方法并列；跨方法对比一律用 union，从 18 个逐细胞预测文件独立重算。

例子：人→斑马鱼 coarse，两个口径差 0.05——足以改变“是否高于基线”的判断。

第 8 页 · 统一口径后的六方向结果

方向	ortholog-PCA	SATURN	scVI
人→鼠	0.6435	0.4147	0.6683
鼠→人	0.6729	0.4010	0.5895
人→斑马鱼	0.1682	0.2479	0.4014
斑马鱼→人	0.1585	0.4021	0.4290
鼠→斑马鱼	0.2314	0.6500	0.4248
斑马鱼→鼠	0.4396	0.6510	0.4786

读数：scVI 四个方向最高，但鼠→人输给 oPCA、鼠→鱼输给 SATURN——没有全面赢家。

限定（口头带过）：SAMap 未画出，三方向 n=0，其余 0.0401–0.1127；分母 oPCA 100%、scVI 98–100%、SATURN 29–87%。

第 9 页 · 场景化选型指南 v0

场景	首选	次选	不推荐	证据强度
近缘（人 ↔ 鼠）	ortholog-PCA	scVI（很接近）	SAMap	中等
远缘 · 人 ↔ 鱼	scVI	SATURN	SAMap	中等
远缘 · 鼠 ↔ 鱼	SATURN	scVI	SAMap	中等
跨门（七鳃鳗 ↔ 鼠）	待跑	—	—	数据已定位
无 GPU	ortholog-PCA	scVI（8.5 min）	SATURN	中等偏强

三条限定语（必须随表一起出现）：

- 全部为 transductive / in-sample，不是留出评估；
- 四方法分母不同（oPCA 100%、scVI 98–100%、SATURN 29–87%、SAMap 0–91%）；
- 「不推荐」≠「方法差」。

一句话：近缘先试 oPCA；跨得越远越要靠联合训练的潜空间方法，但人↔鱼与鼠↔鱼的首选不同；没有 GPU 时 scVI 只要 8.5 分钟。

跨门仍是 insufficient evidence：数据已定位，但尚未跑。

附一 · 数字速查（回答提问时用）

项	值
人→鼠 coarse accuracy	0.8618（1,297 / 1,505）
同源基因（人鼠）	15,869
联合 PCA	3,063 × 50
排除	30（鼠侧 status ≠ active）
coverage	0.9805
majority 准确率	0.4817
majority macro-F1	0.0813
macro-F1 人→斑马鱼 coarse	truth-only 0.4516 / union 0.4014
四方法分母	oPCA 100%、scVI 98–100%、SATURN 29–87%、SAMap 0–91%

附二 · 两个预设追问

“为什么不直接用 macro-F1 报就好了？”

macro-F1 对少数类敏感，但它依赖标签集合的定义；同一份预测在 truth-only 与 union 下差 0.05。所以指标之外必须同时交代口径与分母。

“这些数字能复现吗？”

能。主源是 metrics.json + 逐细胞预测文件，脚本与输入的 SHA-256 都记在 manifest 里；本地已用独立实现重算过 accuracy（18/18 一致）与 macro-F1（差异全部可由口径解释）。

本文所有数字来自平台产物或本地独立重算，未凭记忆填写。口径：transductive / in-sample，单 seed（0）。