

康复大学

University of Health and Rehabilitation Sciences

课题 5 第二阶段汇报：数字来源链

一个百分比是怎样得到的——从原始细胞到表格单元格的完整可复核路径

汇报 2 / 10 · 不报新数字，只讲数字怎么来 | 口径： transductive / in-sample · seed 0 · KNN15 cosine · 2026 年 10 月



一个百分比是怎样得到的：六段可复核链

① 输入
local_*.h5ad
人 1528 / 鼠 1535
鱼 1543 细胞

② 归一化
normalize_total(1e4)
+ log1p
(= log1p(CPM/100))

③ 表示层
ortholog 交集 +PCA50
ESM2→macrogenes
SAMap 同源图

④ 角色
src = reference
(拟合)
tgt = query （预测）

⑤ 评分
KNN15 · cosine
倒距离加权
200 次置换

⑥ 分母
status≠active 排除
correct / n_q
+ coverage

终点： metrics.json → SHA-256 → 汇报表格。每一步都能沿文件与公式复算。

四个必须并列报告的量

- accuracy = correct / n_q （主指标）
- n_q / coverage = 进入分母的细胞数及其占比
- majority = 最大真值类占比（无信息基线）
- shuffle_p = 预测向量置换检验

为什么不能只报一个百分比

- 换掉六段链中任何一段，数字都会变
- 排除规则改变分母 → 分母效应真实存在
- 同一嵌入在不同评分器下不是同一测量
- 跨方法标签空间不同 → 不可直接互比

一句话：准确率 = 正确预测数 ÷ 排除后仍有资格进入分母的 query 细胞数。

例 1： ortholog-PCA 人→鼠 coarse = 86.18%

步骤	内容	值
输入	reference = 人； query = 鼠	1,528 / 1,535 细胞
归一化	normalize_total(1e4) + log1p （全基因空间）	等价 log1p(CPM/100)
同源基因	人鼠 1:1 直系同源交集	15,869 基因
表示层	人 + 鼠联合 PCA-50 （seed 0，transductive）	3,063 × 50
评分	KNN15 · cosine · 倒距离加权	k = 15
排除	鼠侧 status≠active （Proliferating cell）	剔 30
eligible query	1,535 − 30	n_q = 1,505
正确数	逐细胞预测 == 真值	1,297
accuracy	1,297 ÷ 1,505	0.8618
coverage / majority	1,505 ÷ 1,535 / 最大真值类占比	0.9805 / 0.4817

逐类分解（confusion 摘录）

- 内皮 720/725 正确（99.3%）
- 成纤维 255/360
- 免疫 197/202 （97.5%）
- 心肌 19/47
- 主要类别命中率高；跨类错误集中在 成纤维→平滑肌（82）、心肌→内皮（27）

要强调

86.18% 不是从表里抄出来的：
它是「正确预测数 ÷ 排除后仍有资格的 query 细胞数」。

输出文件： results/pilot-v1/ortholog-pca-v98/metrics.json （SHA b2b3ac6b…c725）

本地已独立复算：从 predictions/ 逐细胞重算 acc/coverage/confusion 与 metrics.json 完全一致。

例 2： SATURN 的三个数字必须分开报告

数字	口径（评分器 + 标签空间）	分母	证据等级
0.6179	v97g 评分器 · mapped-space （映射后粗类）	coverage 0.9805 → n_q≈1,505	confirmed （日志级）
0.4749	v99 统一评分器 · exact （原始标签）	n_q = 1,535	candidate （provenance confirmed）
0.4844	v99 统一评分器 · coarse （原始标签 +status 过滤）	n_q = 1,505	candidate （provenance confirmed）

为什么不能合并成一个 SATURN 成绩

- 0.6179 与 0.4749/0.4844 是同一批 SATURN 嵌入在不同评分器 + 不同标签空间下的结果
- 不是 " 同一指标的两次测量 "，不能写成 "SATURN 从 61.79% 降到 48.44%"
- v97g 无逐细胞文件（日志级）；v99 有完整 46 文件树 provenance

引用规则（写进报告）

凡出现 SATURN 数字，必须同时写：

① 哪个评分器（v97g / v99）
② 哪个标签空间（mapped / exact / coarse）
③ 分母 n_q 与排除规则
④ 证据等级（日志级 / 文件级）

本页三个数字的差别不是 " 版本更新 "，而是协议不同——这正是下一阶段（汇报 3）要展开的内容。

例 3：分母效应实证——正确数不变，准确率上升

v99 统一评分器 · human→mouse · 本地逐细胞独立复算（1,535 行载荷）

层	计分细胞数	正确数	accuracy	说明
exact （原始标签）	1,535 （全部）	729	729 ÷ 1535 = 0.4749	不做排除
排除的 30 个细胞	—	0 / 30	—	增殖细胞，全部预测错误
coarse （+status 过滤）	1,505	729	729 ÷ 1505 = 0.4844	分母缩小，分子不变

这说明什么

- 被排除的 30 个增殖细胞全部是错的
- 排除它们后：分子不变（729）、分母变小（1535→1505）
- accuracy 从 0.4749 升到 0.4844

→ 排除规则本身就会改变准确率

因此引用规则

- 任何 acc 必须并列 n_q 与 coverage
- 两个 acc 只有在同一分母口径下才能比较
- 排除数不是 " 清洗细节 "，是协议的一部分
- 30/44/0 的排除普查要随表报告

这是本阶段最有说服力的一个例子：同一批细胞、同一个嵌入，只改分母，数字就变了。

例 4： SAMap WDL 人→鼠 coarse = 10.50%

步骤	内容	值
运行通道	WDL 流程任务（绕开离线通道故障）	W202610050003104
实际运行脚本	410 行版（非 Phase 5 修复版）	sha256 c0f05b89…3807
依赖栈	预建 pylibs （ samap 1.0.16 + samalg 1.0.2 + hnswlib shim ）	复用，非重装
预处理	cell_median + log + StandardScaler(npcs=100)	k = 20
联合对齐	SAMAP(keys=cell_type) 同源基因图，NUMITERS=3	label-aware
评分	KNN15 · cosine · 倒距离加权（与 v99 同评分器）	—
reference / query	人 1,528 / 鼠 1,535	剔 30
n_q / 正确数	1,505 / 158	158 ÷ 1505
accuracy	—	0.1050

三个必须声明的限制

① label-aware： keys=cell_type 使真值参与联合图构建
→ 与 ortholog-PCA （ label-free ）不可直接互比

② 脚本版本：本次为 WDL 实际运行脚本（ 410 行版）
Phase 5 修复版（ 0a2063d3 ）在 WDL 环境下未运行
→ 不能把两者说成同一次运行

③ per_cell 旗标： included=1,398 与 n_q=1,505
口径不同、不参与 acc ； 复算按全部 query 行

读数（不是 " 接近随机 " ）

0.1050 远低于多数类 0.4618 。
confusion 显示预测大量塌缩到单一类别：
内皮 695 个中 634 个被预测为 Lymphoid （ 91.2% ）。

→ 是 " 系统性错位 " ， 不是噪声。

SAMap 结论限于：当前数据、当前协议、当前运行脚本下的探索性复现；不能推广为 " 工具无效 " 。

例 5： 斑马鱼方向为什么低于多数类

量	值
query / reference	鱼 1,543 / 人 1,528
同源基因（人鱼 1:1）	9,131
排除（mt 30 + Proliferating 14）	44
n_q	1,499
coverage	0.9715
正确数	294
accuracy	294 ÷ 1499 = 0.1961
majority	0.3976
shuffle_p	0.0

单 seed 提示：鱼方向 seed 双峰已证实；本页为单 seed （0）点估计，不应读作该方向的稳定值。

两个数字的正确读法

- accuracy 0.1961 < majority 0.3976
  → 该方向没有可靠的类别迁移优势（低于 " 全猜最大类 "）

- shuffle_p = 0.0
  → 只说明优于 " 随机洗牌预测向量 " 的零分布（E[null]≈0.10）
  → 不能读成 " 优于多数类 "

confusion 证据：错误是系统性的

- 鱼红细胞 287/332 预测为 immune
- 鱼内皮 509/596 预测为 immune
- 鱼平滑肌 68/166 预测为 immune

→ 跨物种错误集中在特定类别对，不是随机噪声。

shuffle_p 检验的是 " 预测向量是否优于随机 "，与 majority 是两条不同的判据——不能互相替代。

复核清单与本阶段结论

听众可以自己验

- ortholog-PCA 某方向：读 metrics.json，对照 predictions/ 与 confusion/ （18 份全在本地）
- SAMap 某方向：读 per_cell → 重算 correct/n_q
- v99：用 SHA d1081cfd 定位 metrics.json；逐细胞载荷在 payloads/ （6 份）
- 排除规则： config/heart-celltype-map-v1.tsv （SHA be985735）
- 评分器： scripts/ortholog_pca_local_v1.py

四个 SHA 锚点

ortholog-PCA metrics
b2b3ac6b…c725

SAMap WDL metrics
3c719399…954f

v99 metrics
d1081cfd…dc261

冻结映射表 v1
be985735…3165

本阶段结论

① 每个百分比都能完整回溯（六段链）
② 分母效应真实且可量化（729 案例）
③ 三方法数字不可直接互比（协议三重差异）
④ 全部仍为 transductive/in-sample

边界：不能推出什么

- 不能推出 " 哪个方法普遍更好 "
- 不能把 61.79% 与 48.44% 合并
- 不能把 shuffle_p 当多数类显著性
- 不能把日志级数字当文件级证据

下一阶段（汇报 3）：三方法公平比较边界——为什么不能按一个总分排冠军。