

课题 5 第 4 次汇报： scVI 臂与批次混合

一个在门内赢了四个方向的方法，为什么在跨门没用

2026-10-23 | 7 次汇报中的第 4 次 | 任务 W202610190042919



为什么加 scVI

· 课程标题点名三个方法： SATURN / SAMap / scVI ； 我们此前只做了前两个 + 自建 oPCA
· 文献依据： LBSPA （ Science 2026 ）用的正是 scVI
· 定位：与 SATURN 同属「一次训练、多方向评估」的潜空间方法，但用基因表达而不是蛋白嵌入

协议

三物种联合训练， batch_key=species ， n_latent=10 ， max_epochs=50 ， early stopping ； 共同 human 轴 9,018 基因； KNN15 cosine ； 200 次置换； seed 0 。

规模： 4,606 细胞（ 1,528 / 1,535 / 1,543 ）。 CPU 2 核， 8.5 分钟，峰值内存 2.37 GB 。

所以 scVI 是纯 CPU 就能跑的方法——这点先记下，后面有用

结果：六方向 macro-F1

方向	oPCA	SATURN	scVI
人→鼠	0.6435	0.4147	0.6683
鼠→人	0.6729	0.4010	0.5895
人→斑马鱼	0.1682	0.2479	0.4014
斑马鱼→人	0.1585	0.4021	0.4290
鼠→斑马鱼	0.2314	0.6500	0.4248
斑马鱼→鼠	0.4396	0.6510	0.4786

scVI 六个方向里 4 个最高；但鼠→人输给 oPCA，鼠→鱼输给 SATURN。没有全面赢家。

限定：分母 oPCA 100%、scVI 98–100%、SATURN 29–87%

批次混合：三项指标

指标	oPCA （PCA-50）	scVI （latent-10）	怎么读
silhouette （类型）	0.0937	0.181	结构存在但不清晰
iLISI （物种 k=30）	1.0124	1.125	理论 1–3，接近 1 = 邻居几乎同物种
kBET 接受率	0.0004	0.0039	几乎全部邻域被拒绝

三项都是 scVI 略好，但量级上两者都属于「几乎没混匀」。

口径提醒： oPCA 是 50 维、 scVI 是 10 维，高维邻域更稀疏，指标天然偏低——不是严格同维对比。

批次混合不是 scVI 的强项，它的优势在标签迁移

看起来矛盾的地方

同一份 scVI latent： iLISI 1.125 （几乎不混），但人→鼠 macro-F1 有 0.6683 （迁移不错）。

解释：潜空间把「细胞类型」与「物种」编码在近似正交的方向上——同类型细胞跨物种彼此靠近，但单个细胞最近的 30 个邻居仍以本物种为主。

所以低 iLISI 不等于方法失败；但两组证据必须一起报，只引一个就是误导。

这也是为什么报告里批次指标与迁移指标必须并列

与另外三个方法的关系

	门内表现	跨门表现
oPCA	近缘最强，远缘最弱	失败（acc 5.8%）
SATURN	鼠↔鱼最强	未测
scVI	四方向最高	失败（acc 4.6–5.8%）
SAMap	三方向 n=0	未测

关键落差：门内人→鱼 scVI 是 oPCA 的 2.4 倍（0.4014 vs 0.1682），跨门两者都塌到 0.065–0.080。

一个方法在门内赢，不代表它在跨门也赢。

下次（第 5 次）：跨门场景的双臂实测

局限

· 全部 transductive / in-sample；单 seed，无置信区间
· 特征空间是共同 9,018 基因轴，与 oPCA 的成对基因集不可横向比较
· 批次指标只有 oPCA 与 scVI 有，SATURN / SAMap 缺
· 跨门结果受注释裁剪影响（小鼠 62.2% 细胞被排除）

三条必带的话

transductive 不等于 inductive；分母不同不能当排名；不推荐不等于方法差。

下次：跨门场景