跨物种单细胞整合：三场景结论与可复现闭环

课题 5 第 3 次汇报（老师七条意见之后的重做） | XenoTransfer v1.0

上次汇报后，老师提了 7 条意见 → 这一轮全部落地

最重要的一件事：我们发现自己的 SATURN 分数被算高了 0.04–0.19，且鼠↔鱼结论因此翻转

本讲三件事：① 三场景分开给结论 ② 每个分数都带偏置 ③ 可复现闭环已跑通

这一轮不是加内容，是纠错。结论有改，而且改得更硬。

一、老师七条意见 → 我们的落地

每条都对应一个可复核的产物

老师意见	我们做了什么	产物
①② 近缘 / 远缘 / 跨门分开说	三场景各自给首选 + 配对检验	§2–§4
③ 百分数要考虑稳定性	10 seed + 20 次数据扰动 + bootstrap CI	bootstrap.json
④ 跟原文一样吗	三篇原文逐条对比，不一致处给原因	report-08 §3
⑤ 实际消耗	四个任务 CPU 秒 / 费用台账 + 峰值内存	resource-ledger.json
⑥ 流程要有名字	XenoTransfer v1.0	交接文档
⑦ 会不会发 GitHub/DCS	GitHub 仓库已在（本地领先 63 提交）； DCS 可发	§6

七条全部有落点，没有一条靠口头回答。

二、最重要的发现： SATURN 分数被口径抬高了

映射不到 coarse 的预测被丢弃 = 按预测结果筛样本

oPCA/scVI 的预测只可能是训练用的 8–9 个 coarse 类，永远不可能「预测到类外」； SATURN 输出原始细胞类型，会预测出 Orthers 、 Ventricular Cardiomyocyte 这类映射不到的标签

旧口径：这些预测连同细胞一起丢掉 → 分母只留「预测恰好可映射」的细胞

后果：鼠↔鱼两向被抬高 0.19 左右，结论直接从「 SATURN 大胜」翻成「 scVI 显著更好」

这不是小修，是结论翻转。所以我们同时报两个口径，对外用公平口径。

三、口径偏差的量化

同一批预测，两种口径差多少

方向	现口径	公平口径	被抬高	被丢掉的细胞
人→鼠	0.4147	0.3402	+0.0745	89
鼠→人	0.4010	0.3118	+0.0892	135
人→斑马鱼	0.2479	0.2051	+0.0428	15
斑马鱼→人	0.4021	0.2139	+0.1882	736
鼠→斑马鱼	0.6500	0.4560	+0.1940	529
斑马鱼→鼠	0.6510	0.4588	+0.1922	456

抬高幅度 0.043–0.194，前四向温和、后两向致命。

四、近缘场景： oPCA 与 scVI 打平

人↔鼠 | macro-F1 ± bootstrap SE

方法	人→鼠	鼠→人	两向均值
oPCA	0.6435±0.0186	0.6729±0.0215	0.6582
scVI	0.6683±0.0206	0.5895±0.0140	0.6289
SATURN	0.4147±0.0152	0.4010±0.0210	0.4079
SAMap	0.1127±0.0141	0.0401±0.0051	0.0764

人→鼠差 – 0.0247 （不显著）； 鼠→人 oPCA 显著更高 +0.0833 。打平 → 选 oPCA （ 27 秒、 1.31 GB 、无 GPU ）。

五、远缘场景：统一选 scVI

鱼参与的四方向 | 注意两个口径的 SATURN 都列出来

方向	oPCA	scVI	SATURN 现	SATURN 公平
人→斑马鱼	0.1654±0.0152	0.4014±0.0117	0.2479	0.2051
斑马鱼→人	0.1512±0.0070	0.4290±0.0119	0.4021	0.2139
鼠→斑马鱼	0.2177±0.0135	0.4248±0.0155	0.6500	0.4560
斑马鱼→鼠	0.4405±0.0144	0.4786±0.0114	0.6510	0.4588

同细胞配对检验：鼠→鱼 SATURN−scVI = −0.1713 、鱼→鼠 = −0.0709 ，两个方向 scVI 都显著更好。

六、跨门场景：这一族方法都做不了

七鳃鳗↔小鼠 | 13 类交集 | 55,694 细胞

方向	方法	accuracy	macro-F1	多数类基线
Lamprey→Mouse	oPCA	0.0575±0.0020	0.0235	0.2168
Lamprey→Mouse	scVI	0.0582±0.0020	0.0241	0.2168
Mouse→Lamprey	oPCA	0.0516±0.0011	0.0257	0.3059
Mouse→Lamprey	scVI	0.0457±0.0011	0.0267	0.3059

accuracy 4.6–5.8%，低于 13 类随机猜的 7.69%； macro-F1 甚至低于多数类基线。这是硬负结果。

七、稳定性：十个 seed 不会给出十个结果

老师问的「一个方法测十次」，我们拆成三种不确定性分别测

方向	10 seed SD	换 10% 细胞 SD	换 10% 基因 SD
人→鼠	0.0017	0.0238	0.0121
鼠→人	0.0025	0.0214	0.0133
人→斑马鱼	0.0032	0.0111	0.0240
斑马鱼→人	0.0030	0.0059	0.0084
鼠→斑马鱼	0.0021	0.0056	0.0210
斑马鱼→鼠	0.0059	0.0282	0.0341

换种子 SD 只有 0.0017–0.0059；换 10% 细胞能到 0.028、换 10% 基因能到 0.034。不确定性来自数据，不来自种子。

八、每个分数都带偏置

四方法 × 六方向全部配 bootstrap SE 与 95% CI

方向	oPCA	scVI	SATURN	SAMap
人→鼠	0.6435±0.0186	0.6683±0.0206	0.4147±0.0152	0.1127±0.0141
鼠→人	0.6729±0.0215	0.5895±0.0140	0.4010±0.0210	0.0401±0.0051
人→斑马鱼	0.1654±0.0152	0.4014±0.0117	0.2479±0.0137	0.0477±0.0042
斑马鱼→人	0.1512±0.0070	0.4290±0.0119	0.4021±0.0178	—
鼠→斑马鱼	0.2177±0.0135	0.4248±0.0155	0.6500±0.0259	—
斑马鱼→鼠	0.4405±0.0144	0.4786±0.0114	0.6510±0.0260	—

22 格全部通过「与冻结值逐格对齐」校验（0 mismatch），所以这些 CI 是挂在已验证数字上的。

九、实际消耗

平台任务台账 + 本地白盒测内存

方法	任务号	实际计算	资源档	费用
oPCA (FIXKEY)	W202610150090794	866 s	2c8g	¥0.19
scVI 门内	W202610190042919	916 s	2c8g	¥0.20
scVI 跨门	W202610220063725	9,773 s	2c8g	¥2.06
SAMap	W202610260103163	354 s	1c4g	¥0.02
合计	4 个任务	11,909 s (3h18m)	—	¥2.47

oPCA 本地白盒测量：墙钟 26.68 s （25.52–26.92），峰值工作集 1307.9 MB

跨门那次占总额 84% （¥2.06/¥2.47），细胞数 12 倍、耗时 10.7 倍——近似线性，不是平方

四个任务合计 11,909 CPU 秒 / ¥2.47 。 SATURN 是 GPU 任务，平台不记 CPU/ 内存，如实标为缺口。

十、可复现闭环：镜像建好， 6 个值在里面逐位复现

g5-opca-container （基于 SATURN--22， 7 个 pip 精确版本）

方向	冻结值	镜像内实测	一致
人→鼠	0.8618	0.8618	✓
鼠→人	0.7369	0.7369	✓
人→斑马鱼	0.1795	0.1795	✓
斑马鱼→人	0.1734	0.1734	✓
鼠→斑马鱼	0.2675	0.2675	✓
斑马鱼→鼠	0.5814	0.5814	✓

镜像构建成功 → 离线任务实测可选中 → 在镜像内跑完整评估， 6/6 逐位一致

7 个包版本全部命中： numpy 1.23.5 / scipy 1.10.1 / pandas 1.5.3 / sklearn 1.6.1 / anndata 0.10.8 / scanpy 1.9.3 / h5py 3.8.0

从「配方看起来完整」到「真的跑出同样数字」，这一步此前从未做到过。

十一、一路上查清的两件事（都是坑）

同名 ≠ 同文件

平台 ortholog_pca_dcs_v3_fixkey.txt （17,382 B / 421 行 / json.loads 在 167 行 / sha 514d9314…）与本地 scripts/*.py （16,463 B / 383 行 / csv.DictReader 在 123 行 / sha f9683cf9…）不是同一文件，同名函数有两种实现

平台版要的映射是 /Files/wheelhouse/v99_mapping_embedded.json （38 条 dict），不是 heart-celltype-map-v1.tsv

平台把任务标成「失败」那次，其实计算成功了——只是脚本最后 cat 了错误的输出目录变量名

教训：先比 wc -c / wc -l / sha256sum，再决定用哪个文件；平台标「失败」要看它退出在哪一步。

十二、跟原文一致吗

三篇原文逐条对比

原文	作者主张	我们复现到哪
SATURN (Nat Methods 2024)	蛙↔鱼 85.8% 中位准确率，比 SAMap 高 119%	方向一致（SATURN>SAMap），但输给 scVI
SAMap (eLife 2021)	同门内全同源图可跨远缘映射	我们只喂 1:1 同源、规模差 300 倍，几乎无信号
HEART (Science 2026)	27 物种心脏图谱，SATURN 整合 16 物种	仅用其小子集，未复现原规模

不一致的三个原因：①原文 scVI 是纯无监督整合，我们加了 KNN 标签迁移层 ②我们的口径偏差（已修） ③ SAMap 靠全同源图，我们只给 1:1

「SAMap 不行」不能说，只能说「在本项目 1,500 细胞 + 1:1 同源约束下无信号」。

十三、还剩什么

三条边界，两条待人做

待人做 ①： mapping 表 38 行 reviewer 仍是 pending，需导师 / 生物学同学签字——而且签之前建议先改 3 行（Orthers→neural 最该改）

待人做 ②： GitHub 推送（本地领先 63 提交，当时代理端口无监听）

明确不做： SATURN 批次指标（重训会产出不同表示，造成假对照）

明确不做：排总分冠军（分母 / 特征空间 / 训练方式 / 统计强度都不同）

明确不做： held-out / inductive 重跑（需新协议与预算，现有结论只声称 transductive）

12 项课程要求： 11 项完成、 1 项部分（批次混合， SATURN 缺席有硬理由）。

如果只记三句

课后能复述的三句

1. 没有全面赢家 → 不排总分，只做「场景 → 方法」

2. 我们自己发现并修正了一个抬高 0.04–0.19 的口径偏差，鼠↔鱼结论因此翻转

3. 所有结论限定在 transductive / in-sample 、 4,606 细胞、且 macro-F1 必须带「 union 口径 + 分母」一起说

算得对是底线，分得对要人签字。